Postpartum Anxiety Symptom Screening
Hybrid Ensemble ও Explainable AI দিয়ে

একটি সহজ ভাষার Project Book

Method · Algorithm · Result · Comparison · SHAP vs LIME · Limitation · Research Gap

Thesis Project · Notebook: `final_thesis_study.ipynb` (৪৭টি Task)

November 2026

সূচিপত্র (Contents)

১	পুরো Project এক নজরে (Summary)
২	Problem কী, আর কেন এই Research
৩	Project-এর যাত্রা: আগের Design বনাম Final Design
৪	Dataset: কী আছে, আর কী সমস্যা পাওয়া গেল
৫	Research Question ও Objective
৬	Methodology: ধাপে ধাপে পুরো কাজ
৭	৫টি Algorithm: কীভাবে কাজ করে, কেন নেওয়া হলো
৮	Proposed Hybrid Ensemble: কীভাবে বানানো ও বাছাই করা হলো
৯	Evaluation Metric ও Statistics
১০	Result: সব Model-এর তুলনা
১১	Validity Check: Leakage, Calibration, Fairness, Sample Size
১২	Explainable AI: SHAP ও LIME কীভাবে কাজ করে
১৩	SHAP vs LIME: পূর্ণ Comparison
১৪	Literature Review ও অন্য Research-এর সাথে Comparison
১৫	Limitation (সীমাবদ্ধতা)
১৬	Research Gap ও Future Work
১৭	Ethics ও Reporting (TRIPOD+AI)
১৮	Conclusion: Thesis-এ কী লিখবেন
A	Appendix A: Notebook-এর ৪৭টি Task
B	Appendix B: Figure ও Result File-এর তালিকা
C	Appendix C: Glossary (শব্দের সহজ অর্থ)
D	Appendix D: Software ও References

১. পুরো Project এক নজরে

এক কথায়: আমরা একটা survey dataset থেকে বুঝতে চেয়েছি, একজন নতুন মা anxious (উদ্বিগ্ন) কি না। এর জন্য ৫টি machine learning model তুলনা করেছি, নিজের একটা Hybrid model বানিয়েছি, আর SHAP ও LIME দিয়ে model-এর সিদ্ধান্ত ব্যাখ্যা করেছি।

বিষয়	সংক্ষেপে
Dataset	Kaggle survey, ১,৫০৩টি row — কিন্তু duplicate বাদ দিলে মাত্র **৩২৬টি unique row**
Target (কী predict করছি)	"Feeling anxious" = Yes না No
Input (feature)	৯টি: Age + ৮টি প্রশ্ন (sad, irritable, sleep, concentration, appetite, guilt, bonding, suicide item)
Algorithm	৫টি: Logistic Regression, Random Forest, Extra Trees, SVM, **Hybrid Ensemble (proposed)**
Testing পদ্ধতি	5-fold cross-validation, ১০ বার repeat = **৫০টি test**
Best model	**Hybrid Ensemble** — overall rank ১
Best result	Balanced accuracy **৭৭.২%**, ROC-AUC **০.৮৪৩**
Explainable AI	SHAP ও LIME দুটোই বলে **Guilt** প্রশ্নটা সবচেয়ে important; দুইটার মিল **৯৮%**
বড় আবিষ্কার	Duplicate রাখলে accuracy হয় **৯৮.৮%** (ভুয়া), বাদ দিলে **৭৬.০%** (আসল)

Result এক নজরে

Model	Balanced Accuracy	ROC-AUC	Overall Rank
Hybrid Ensemble (proposed)	**৭৭.২%**	**০.৮৪৩**	**১**
Random Forest	৭৭.১%	০.৮৪৩	২
Extra Trees	৭৬.০%	০.৮৪৮	৩
SVM	৭৬.৭%	০.৮২২	৪
Logistic Regression	৭৩.০%	০.৮০০	৫

মনে রাখুন: Hybrid প্রথম হয়েছে, কিন্তু Random Forest-এর থেকে পার্থক্য খুব কম (০.১%) এবং statistically significant না। আর এটা একটা screening help tool, doctor-এর diagnosis-এর বিকল্প না।

২. Problem কী, আর কেন এই Research

এক কথায়: অনেক research ছোট dataset-এ ৯৫–৯৯% accuracy দাবি করে, কিন্তু data leakage ও ব্যাখ্যার অভাবে সেই result বিশ্বাস করা কঠিন। আমরা সৎভাবে, leakage ছাড়া মেপেছি এবং model-কে explain করেছি।

২.১ বাস্তব সমস্যা

বাচ্চা জন্মের পর অনেক মা depression বা anxiety-তে ভোগেন। প্রায় ২০% মা পর্যন্ত এতে আক্রান্ত হতে পারেন। কিন্তু অনেকেই চিহ্নিত হন না। তাই সহজ কিছু প্রশ্নের উত্তর থেকে ঝুঁকি আগে ধরতে পারলে উপকার হয়।

২.২ ML research-এর তিনটা সাধারণ ভুল

সমস্যা	সহজ ভাষায় মানে	এই project-এ সমাধান
Data leakage	একই row training আর testing দুই জায়গায় চলে যায়, model উত্তর মুখস্থ করে ফেলে	Split-এর আগেই duplicate বাদ
একবার মাত্র test	একটা train/test split-এ result ভাগ্যের উপর নির্ভর করে	৫০ বার test, তারপর গড়
Black-box model	Model কেন সিদ্ধান্ত নিল বোঝা যায় না	SHAP ও LIME দিয়ে ব্যাখ্যা

২.৩ এই project-এর Contribution

#	Contribution	কোথায় দেখবেন
১	Dataset-এর quality audit (duplicate, missing value, অস্বাভাবিক সম্পর্ক)	অধ্যায় ৪
২	Leakage ছাড়া ৫টি algorithm-এর fair comparison	অধ্যায় ১০
৩	নিজের Hybrid Ensemble model, আলাদা data-তে বাছাই করে confirm করা	অধ্যায় ৮
৪	SHAP vs LIME-এর সংখ্যা দিয়ে comparison	অধ্যায় ১৩
৫	প্রকাশিত ৯৭% result যে leakage থেকে এসেছে, তার প্রমাণ	অধ্যায় ১১

৩. Project-এর যাত্রা: আগের Design বনাম Final Design

এক কথায়: Project তিনবার দিক বদলেছে। প্রতিবার বদলের কারণ ছিল data থেকে পাওয়া প্রমাণ।

ধাপ	কী ছিল	সমস্যা কী ছিল	কী করা হলো
১. শুরুর Title	"Early Screening and Risk Stratification of Postpartum Depression and Anxiety"	Data-তে depression label নেই, সময়ের তথ্য নেই	Title ছোট ও সৎ করা হলো
২. প্রথম Notebook	একবার ৮০/২০ split, ৬৬টা test row	Result ৬৭% থেকে ৮৬% পর্যন্ত ওঠানামা; test দেখে model বাছাই	৫০ বার test চালু
৩. CGTH Design	Logistic Regression নিশ্চিত হলে নিজে সিদ্ধান্ত নেয়, না হলে Random Forest-কে দেয়	Accuracy একটু কমে (৭৫.৭%), কঠিন test-এ pass করেনি	বাদ দেওয়া হলো (git history-তে আছে)
৪. Final Design	৫টি algorithm + Hybrid Ensemble + SHAP/LIME	—	সহজ, পরিষ্কার, সবচেয়ে ভালো result

আগের Design বনাম Final Design

দিক	আগের Design (CGTH)	Final Design
Main model	LR → RF gate	RF + ET + SVM soft voting
Balanced accuracy	৭৫.৭%	**৭৭.২%**
Rank	মাঝামাঝি	**১ নম্বর**
Explainability	৬৮% সিদ্ধান্ত LR দিয়ে	১০০% সিদ্ধান্ত SHAP ও LIME দিয়ে ব্যাখ্যা
Code-এর জটিলতা	বেশি	কম (৪৭টা ছোট task)

8. Dataset: কী আছে, আর কী সমস্যা পাওয়া গেল

এক কথায়: ১,৫০৩টা row-এর মধ্যে ১,১৭৭টাই duplicate। আসল unique উত্তর মাত্র ৩২৬টা। কিছু সম্পর্কও অস্বাভাবিক।

8.১ Dataset-এর পরিচয়

বিষয়	তথ্য
Source	Kaggle, "PostPartum Depression" (uploader: parvezalmuqtadir2348)
কীভাবে সংগ্রহ	একটা হাসপাতালে Google Form দিয়ে (অন্য website-এর তথ্য অনুযায়ী)
Size	১,৫০৩ row × ১১ column
File	`data/raw/postpartum_depression.csv` (শুধু পড়া হয়, কখনো বদলানো হয় না)
License	**এখনো verify করা হয়নি**

৪.২ প্রতিটি Column ও তার উত্তর

Column	সহজ নাম	সম্ভাব্য উত্তর	ভূমিকা
Age	বয়স	25-30, 30-35, 35-40, 40-45, 45-50	Feature
Feeling sad or Tearful	দুঃখ / কান্না	Yes, No, Sometimes	Feature
Irritable towards baby & partner	খিটখিটে মেজাজ	Yes, No, Sometimes	Feature
Trouble sleeping at night	ঘুমের সমস্যা	Yes, No, Two or more days a week	Feature
Problems concentrating	মনোযোগের সমস্যা	Yes, No, Often	Feature
Overeating or loss of appetite	খাওয়ার সমস্যা	Yes, No, Not at all	Feature
Feeling of guilt	অপরাধবোধ	Yes, No, Maybe	Feature
Problems of bonding with baby	বাচ্চার সাথে bonding	Yes, No, Sometimes	Feature
Suicide attempt	আত্মহত্যা-সংক্রান্ত প্রশ্ন	Yes, No, Not interested to say	Feature
Feeling anxious	উদ্বিগ্ন কি না	Yes, No	**Target**
Timestamp	সময়	তারিখ ও সময়	বাদ দেওয়া হয়েছে

৪.৩ Data Audit-এর Result

Check	Result	এর মানে কী
Duplicate row	**১,১৭৭টা (৭৮%)**	আসল unique উত্তর মাত্র ৩২৬টা
আলাদা timestamp	মাত্র ৯০টা	এক মিনিটে ৫১টা পর্যন্ত entry — বাস্তবে অস্বাভাবিক; data copy করা হতে পারে
Missing value	Raw data-তে ২৭টা, unique row-এ ৯টা	খুব কম; সবচেয়ে common উত্তর দিয়ে পূরণ করা হয়েছে
Target balance	Anxious ১৮৯ (৫৮%), Not anxious ১৩৭ (৪২%)	হালকা imbalance; তাই balanced accuracy প্রধান metric
Guilt বনাম Anxious	Guilt = No হলে ৮১% anxious; Guilt = Yes হলে মাত্র ২০%	উল্টো সম্পর্ক — clinically অস্বাভাবিক
Sad বনাম Anxious	প্রায় কোনো সম্পর্ক নেই	বাস্তব data-তে আশা করা যায় না

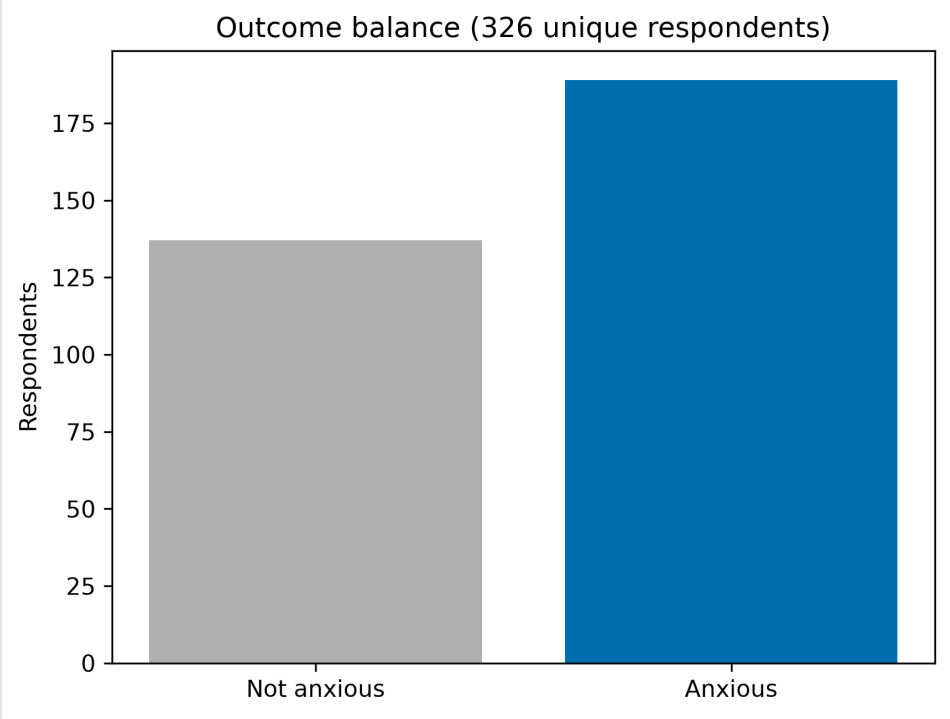


Figure 1: ৩২৬ জনের মধ্যে Anxious ১৮৯ জন, Not anxious ১৩৭ জন (Task 7)

8.8 Duplicate বাদ দেওয়া কেন জরুরি

	Duplicate রাখলে	Duplicate বাদ দিলে
Test row-এর কত % training-এও আছে	**৯৪.৪%**	০%
Random Forest accuracy	**৯৮.৮%** (মুখস্থ)	**৭৬.০%** (আসল শেখা)
Result বিশ্বাসযোগ্য?	না	হ্যাঁ

৫. Research Question ও Objective

এক কথায়: ৪টা প্রশ্নের উত্তর খুঁজেছি — কোন model best, overfitting আছে কি না, কোন প্রশ্ন সবচেয়ে important, আর duplicate কতটা ভুয়া result দেয়।

৫.১ Objective

#	Objective	কোথায় করা হয়েছে
O1	Dataset-এর quality check করা	Task 3–7
O2	Leakage ছাড়া ৫টি algorithm compare করা	Task 8–23
O3	নিজের Hybrid model বানানো ও test করা	Task 13–23
O4	SHAP ও LIME দিয়ে explain ও compare করা	Task 33–46
O5	Calibration, fairness, sample size, leakage check	Task 24–32

৫.২ Research Question ও Answer

প্রশ্ন	Answer
RQ1: Leakage ছাড়া কোন model best?	Hybrid Ensemble overall ১ নম্বর (৭৭.২%), তবে পার্থক্য significant না
RQ2: কোনো model কি overfit করছে?	হ্যাঁ, tree model-গুলো কিছুটা; Extra Trees সবচেয়ে বেশি (১৭.১ point gap)
RQ3: কোন প্রশ্ন সবচেয়ে important? SHAP ও LIME কি একমত?	Guilt; তারপর Appetite ও Irritable। SHAP ও LIME-এর মিল ০.৯৮৩
RQ4: Duplicate কতটা ভুয়া result দেয়?	৭৬.০% থেকে বেড়ে ৯৮.৮% — প্রায় ২৩ point ভুয়া বৃদ্ধি

৬. Methodology: ধাপে ধাপে পুরো কাজ

এক কথায়: Data clean → duplicate বাদ → preprocessing → ৫টা model train → ৫০ বার test → statistics → SHAP/LIME দিয়ে explain।

৬.১ পুরো Pipeline

Step	কী করা হয়েছে	কেন	Task
১	Data load	CSV পড়া, কিছু বদলানো হয় না	3
২	Duplicate বাদ	Leakage বন্ধ করতে	4–5
৩	X (feature) ও y (target) আলাদা	Model-কে input ও answer আলাদা দিতে	6
৪	Missing value পূরণ	Model ফাঁকা ঘর নিতে পারে না	8
৫	One-hot encoding	Text উত্তরকে number-এ রূপান্তর	8
৬	৫টা model তৈরি	Comparison-এর জন্য	9–14
৭	৫০ বার train ও test	নির্ভরযোগ্য result	16
৮	Table, CI, statistical test, ranking	কে best, আর পার্থক্য আসল কি না	17–23
৯	ROC, confusion matrix, calibration, fairness	বিস্তারিত বিশ্লেষণ	24–29
১০	Leakage check	Duplicate-এর প্রভাব মাপা	30–32
১১	SHAP ও LIME	Model-এর সিদ্ধান্ত ব্যাখ্যা	33–44
১২	Final comparison	Thesis-এর জন্য ৩টা final table	45–47

৬.২ Preprocessing কেন এভাবে?

বিষয়	কী ব্যবহার	কেন
Missing value	`SimpleImputer(most_frequent)`	সব column categorical, আর missing খুব কম
Encoding	`OneHotEncoder`	"Yes/No/Maybe"-এর মধ্যে কোনো ক্রম নেই; 0/1/2 দিলে model ভুল দূরত্ব ধরে
Pipeline	`make_pipeline`	প্রতিটা training অংশের ভেতরেই শেখে, test data-র তথ্য ঢোকে না

৬.৩ Testing পদ্ধতি: Repeated 5-fold Cross-Validation

Data-কে ৫ ভাগ করি। প্রতিবার ৪ ভাগে training, ১ ভাগে testing। এভাবে ৫ বার। পুরো কাজটা ১০ বার আলাদা আলাদা shuffle করে করি। মোট **৫০টা test**।

পদ্ধতি	Test সংখ্যা	সমস্যা / সুবিধা
একবার 80/20 split	১টা (৬৬ row)	Result ৬৭–৮৬% ওঠানামা করে — ভাগ্যের উপর নির্ভর
5-fold CV	৫টা	ভালো, কিন্তু এখনো কিছুটা অস্থির
Repeated 5-fold × 10	**৫০টা**	**সবচেয়ে স্থির ও নির্ভরযোগ্য**

৬.৪ সব Model-এর জন্য একই নিয়ম (Fair Comparison)

- একই ৫০টা test ভাগ (একই random seed = 42)।
- একই preprocessing, একই 0.5 threshold।
- Hyperparameter আগেই ঠিক করা; test result দেখে বদলানো হয়নি।
- Training score ও testing score দুটোই রাখা হয়েছে, যাতে overfitting মাপা যায়।

৭. ৫টি Algorithm: কীভাবে কাজ করে, কেন নেওয়া হলো

> **এক কথায়:** প্রতিটা algorithm আলাদা নিয়মে শেখে। তাই আমরা প্রতিটা "পরিবার" থেকে একটা করে নিয়েছি, আর তিনটা মিলিয়ে Hybrid বানিয়েছি।

৭.১ পাশাপাশি Comparison

Algorithm	কীভাবে কাজ করে (সহজ ভাষায়)	সুবিধা	অসুবিধা
Logistic Regression	প্রতিটা উত্তরকে একটা weight দেয়, যোগ করে probability বানায়	সহজ, সবচেয়ে বেশি explainable, overfitting কম	প্রশ্নগুলোর মধ্যে জটিল সম্পর্ক ধরতে পারে না
Random Forest	৩০০টা decision tree বানায়, সবার vote-এর গড় নেয়	জটিল সম্পর্ক ধরে, ছোট data-তেও স্থির	ভেতরে কী হচ্ছে দেখা কঠিন
Extra Trees	Random Forest-এর মতো, কিন্তু split একদম random	খুব বৈচিত্র্যময় tree, AUC ভালো	Overfitting সবচেয়ে বেশি
SVM	দুই group-এর মাঝে সবচেয়ে চওড়া সীমারেখা খোঁজে	Tree থেকে সম্পূর্ণ আলাদা নিয়ম	সরাসরি probability দেয় না, calibration লাগে
Hybrid Ensemble	**RF, ET, SVM-এর probability-র গড়**	**তিনজনের ভুল একে অপরকে পুষিয়ে দেয়**	**বেশি সময় লাগে, explain করতে SHAP/LIME লাগে**

৭.২ প্রতিটা Algorithm-এর Formula ও Setting

Logistic Regression (Task 9)

$$p(\text{anxious}) = 1 / (1 + e^{-(\beta_0 + \beta_1 x_1 + \ldots + \beta_k x_k)})$$

Random Forest (Task 10)

$$p_{RF} = (\text{৩০০টা tree-এর probability-র গড়})$$

Extra Trees (Task 11)

Random Forest-এর মতোই গড়, কিন্তু প্রতিটা split-এর সীমা random, আর bootstrap sample নেই।

SVM (Task 12)

$$\text{RBF kernel: } K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

Hybrid Ensemble (Task 13)

$$p_{\text{Hybrid}} = (p_{\text{RF}} + p_{\text{ET}} + p_{\text{SVM}}) / 3 \;\rightarrow\; p \geq 0.5 \text{ হলে "Anxious"}$$

Algorithm	Setting (Hyperparameter)	কেন এই setting
Logistic Regression	L2 regularization, max_iter = 2000	Default, নিরাপদ
Random Forest	300 tree, max_depth = 6, min_samples_leaf = 3	Overfitting কমাতে tree ছোট রাখা
Extra Trees	300 tree, max_depth = 8, min_samples_leaf = 3	একটু গভীর, কারণ split random
SVM	RBF kernel, C = 1, sigmoid calibration (5-fold)	Probability পেতে calibration দরকার
Hybrid Ensemble	উপরের RF + ET + SVM, soft voting	তিনটা ভিন্ন নিয়মের মিলন

৭.৩ কেন শুধু ৫টা?

আগে আরও অনেক model test করা হয়েছিল। কেউই এই ৫টার চেয়ে ভালো করেনি:

আগে test করা Model	Balanced Accuracy	Final-এ রাখা হয়েছে?
Gradient Boosting	৭৩.৪–৭৩.৭%	না (কম)
Naive Bayes	৭৩.২–৭৩.৩%	না (কম)
k-Nearest Neighbours	৬৯.২%	না (সবচেয়ে কম)
Stacking (RF + ET + NB)	৭৬.৬%	না (Hybrid-এর চেয়ে কম)

৮. Proposed Hybrid Ensemble: কীভাবে বানানো ও বাছাই করা হলো

এক কথায়: ৫৫টা সম্ভাব্য hybrid test করেছি, দুইটা আলাদা run-এ। "RF + ET + SVM" দুইবারই প্রথম হয়েছে। তারপর তৃতীয় একটা আলাদা run-এ আবার প্রথম হয়েছে।

৮.১ Idea

প্রতিটা model আলাদা ধরনের ভুল করে। তিনটা ভিন্ন নিয়মের model-এর গড় নিলে একজনের ভুল অন্যরা ঠিক করে দেয়। ফলে prediction বেশি স্থির হয়।

৮.২ কীভাবে বাছাই করা হলো

Step	কী করা হয়েছে
১	৬টা base model নেওয়া: LR, RF, ET, SVM, Naive Bayes, Gradient Boosting
২	এদের দিয়ে ৫৫টা hybrid বানানো: ২–৪টা model-এর সব soft voting combination (৫০টা) + ৫টা stacking
৩	Development run ১ (seed 7) ও run ২ (seed 2026)-এ সবাইকে test
৪	দুই run মিলিয়ে best: **RF + ET + SVM**
৫	Final run (seed 42)-এ confirm — আবার ১ নম্বর

৮.৩ Development Run-এর Top ৫

Candidate	Balanced Accuracy (গড়)	ROC-AUC (গড়)	Rank
Vote RF + ET + SVM	**৭৬.৫%**	**০.৮৩৯**	**১**
Vote RF + ET	৭৬.০%	০.৮৪৩	২ (সমান)
Random Forest (একা)	৭৬.৩%	০.৮৩৯	২ (সমান)
Vote ET + SVM	৭৬.৩%	০.৮৩৯	৪
Stack RF + ET + NB	৭৫.৯%	০.৮৪১	৫

কেন এটা গুরুত্বপূর্ণ: Model বাছাই করা হয়েছে আলাদা data-split-এ, final result-এর split দেখে নয়। তাই final result "টিউন করা" বা "cherry-pick করা" না।

৮.৪ যে Hybrid Idea কাজ করেনি

Idea	Result	শিক্ষা
Confidence gate (LR → RF)	৭৫.৭%	Explainability বাড়ে, accuracy একটু কমে
Confidence gate (LR → Hybrid)	৭৫.৯%	একই ব্যাপার
Tree rule + Logistic Regression	AUC ০.৮০	LR-এর চেয়ে ভালো না
Training data দিয়ে threshold ঠিক করা	সব model-এ একটু খারাপ	ছোট data-তে overfitting হয়

৯. Evaluation Metric ও Statistics

এক কথায়: শুধু accuracy না দেখে ৭টা metric দেখেছি। Balanced accuracy প্রধান, কারণ data-তে Anxious বেশি (৫৮%)।

৯.১ Confusion Matrix-এর ৪টা ঘর

	Model বলল: Anxious	Model বলল: Not anxious
আসলে Anxious	TP — ঠিক ধরেছে	FN — miss করেছে
আসলে Not anxious	FP — ভুল alarm	TN — ঠিক বাদ দিয়েছে

৯.২ Metric-এর তালিকা

Metric	Formula	সহজ মানে	ভালো মান
Sensitivity	TP / (TP + FN)	Anxious-দের কত % ধরতে পারল	বেশি
Specificity	TN / (TN + FP)	Not anxious-দের কত % ঠিক বাদ দিল	বেশি
Balanced Accuracy	**(Sensitivity + Specificity) / 2**	**দুই group-কে সমান গুরুত্ব দিয়ে accuracy**	**বেশি**
Accuracy	(TP + TN) / মোট	মোট কতগুলো ঠিক	বেশি
F1 Score	2·Precision·Recall / (Precision + Recall)	Precision ও recall-এর balance	বেশি
MCC	(TP·TN − FP·FN) / √(…)	−1 থেকে +1; imbalance-এ সবচেয়ে fair	বেশি
ROC-AUC	ROC curve-এর নিচের area	Anxious-কে বেশি score দেওয়ার ক্ষমতা	0.5 = অনুমান, 1 = perfect
Brier Score	$(1/n)\ \Sigma\ (p - y)^2$	Probability কতটা সঠিক	কম

৯.৩ Statistics কেন ও কীভাবে

Tool	কী করে	Formula / নিয়ম
Corrected 95% CI	Result কতটা নিশ্চিত, তার পরিসর	mean ± 1.96 × $\sqrt{[(1/k + n_{test}/n_{train}) \cdot s^2]}$
Corrected paired t-test	দুই model-এর পার্থক্য আসল কি না	t = গড় পার্থক্য / SE, df = 49
Bonferroni correction	৪টা comparison একসাথে করায় ভুয়া significant আটকায়	corrected p = p × 4 (সর্বোচ্চ 1)
Overall rank	সব মিলিয়ে কে best	(Balanced accuracy rank + ROC-AUC rank) / 2

"Corrected" কেন: cross-validation-এ training অংশগুলো একে অপরের সাথে অনেকটা মিলে যায়। সাধারণ formula তখন uncertainty কম দেখায়। Nadeau–Bengio correction এটা ঠিক করে।

১০. Result: সব Model-এর তুলনা

এক কথায়: Hybrid Ensemble overall ১ নম্বর। Balanced accuracy, accuracy ও MCC-তে সবার উপরে। কিন্তু Random Forest প্রায় সমান, আর পার্থক্য significant না।

১০.১ Main Result Table (৫০টা test-এর গড়)

Model	Bal. Acc.	Accuracy	Sensitivity	Specificity	F1	MCC	ROC-AUC	Rank
Hybrid Ensemble	**৭৭.২%**	**৭৮.৫%**	**৮৫.৪%**	**৬৯.০%**	**৮২.১%**	**০.৫৫৮**	**০.৮৪৩**	**১**
Random Forest	৭৭.১%	৭৮.৫%	৮৬.১%	৬৮.১%	৮২.৩%	০.৫৫৮	০.৮৪৩	২
Extra Trees	৭৬.০%	৭৭.০%	৮২.৫%	৬৯.৫%	৮০.৬%	০.৫২৯	০.৮৪৮	৩
SVM	৭৬.৭%	৭৮.১%	৮৫.৩%	৬৮.০%	৮১.৮%	০.৫৪৯	০.৮২২	৪
Logistic Regression	৭৩.০%	৭৪.৫%	৮২.১%	৬৩.৯%	৭৮.৮%	০.৪৭৩	০.৮০০	৫

১০.২ কোন Metric-এ কে জিতেছে?

Metric	Winner	মান	Hybrid-এর মান
Balanced Accuracy (প্রধান)	**Hybrid Ensemble**	৭৭.২%	৭৭.২% ✅
Accuracy	**Hybrid** ও Random Forest (সমান)	৭৮.৫%	৭৮.৫% ✅
MCC	**Hybrid** ও Random Forest (সমান)	০.৫৫৮	০.৫৫৮ ✅
Sensitivity	Random Forest	৮৬.১%	৮৫.৪% (২য়)
F1	Random Forest	৮২.৩%	৮২.১% (২য়)
Specificity	Extra Trees	৬৯.৫%	৬৯.০% (২য়)
ROC-AUC	Extra Trees	০.৮৪৮	০.৮৪৩ (২য়)
সবচেয়ে কম Overfitting	Logistic Regression	৪.৫ point gap	১০.২ (৪র্থ)
Overall Rank	**Hybrid Ensemble**	**১.৭৫**	**১ নম্বর** ✅

> Performance metric-গুলোতে Hybrid কখনো ২য়-র নিচে নামেনি। এটাই ensemble-এর শক্তি — সব দিকে ধারাবাহিকভাবে ভালো। (শুধু overfitting gap-এ এটা ৪র্থ।)

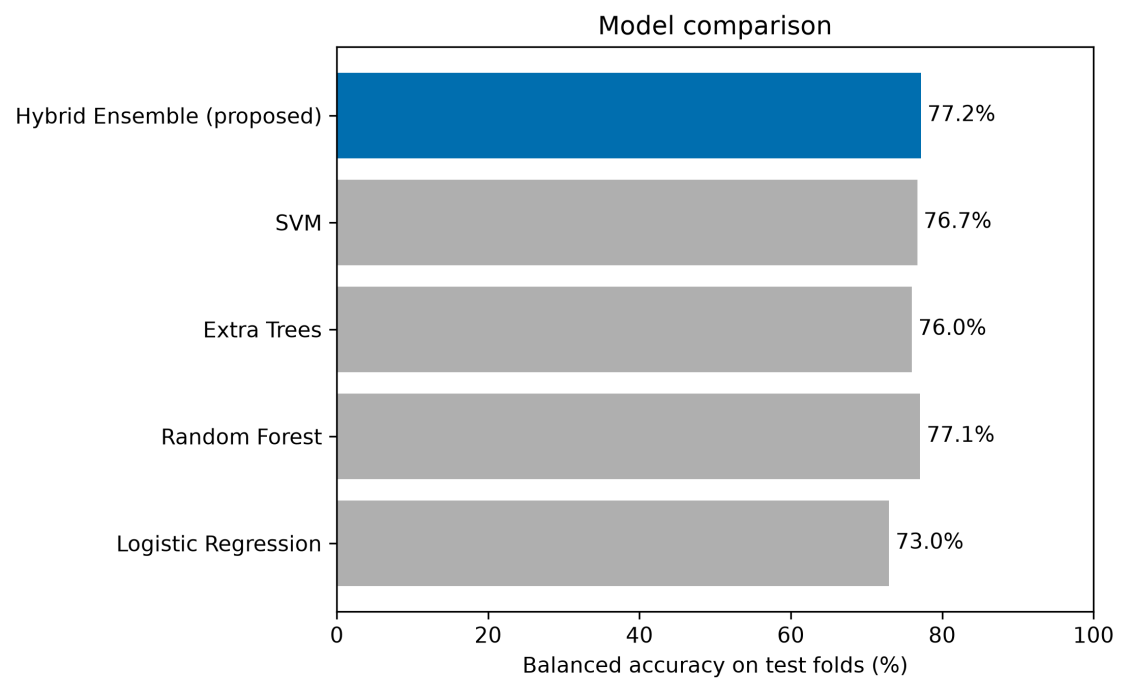


Figure 2: Test balanced accuracy — নীল বার = proposed Hybrid (Task 20)

১০.৩ 95% Confidence Interval

Model	Mean	Lower 95%	Upper 95%	Range-এর width
Hybrid Ensemble	**০.৭৭২**	**০.৭২১**	**০.৮২৩**	**০.১০২**
Random Forest	০.৭৭১	০.৭১৯	০.৮২৩	০.১০৪
SVM	০.৭৬৭	০.৭১৬	০.৮১৮	০.১০২
Extra Trees	০.৭৬০	০.৭১১	০.৮০৯	০.০৯৮
Logistic Regression	০.৭৩০	০.৬৬৮	০.৭৯২	০.১২৪

সব model-এর range প্রায় ১০ point চওড়া, কারণ data ছোট (৩২৬ row)। Range-গুলো একে অপরের উপর পড়েছে (overlap) — তাই পার্থক্য significant না।

১০.৪ Statistical Test: Hybrid বনাম বাকিরা

Hybrid vs	পার্থক্য	p-value	Corrected p	Significant?
Logistic Regression	+৪.২ point	০.০৩৮	০.১৫৩	না
Extra Trees	+১.২ point	০.২৭৬	১.০০	না
SVM	+০.৫ point	০.৪৬৯	১.০০	না
Random Forest	+০.১ point	০.৮৭৯	১.০০	না

> **Thesis-এ কীভাবে লিখবেন:** "Hybrid Ensemble overall rank-এ ১ নম্বর, কিন্তু অন্য model-এর সাথে পার্থক্য statistically significant না।" শুধু "Hybrid best" লিখবেন না — reviewer এটা ধরবে।

১০.৫ Training বনাম Testing (Overfitting Check)

Model	Training	Testing	Gap	মন্তব্য
Logistic Regression	৭৭.৬%	৭৩.০%	৪.৫	সবচেয়ে কম overfit, কিন্তু সবচেয়ে দুর্বল
Random Forest	৮৪.৬%	৭৭.১%	৭.৫	ভালো balance
SVM	৮৬.২%	৭৬.৭%	৯.৬	মাঝারি
Hybrid Ensemble	**৮৭.৪%**	**৭৭.২%**	**১০.২**	**মাঝারি, test-এ best**
Extra Trees	৯৩.১%	৭৬.০%	১৭.১	সবচেয়ে বেশি মুখস্থ করে

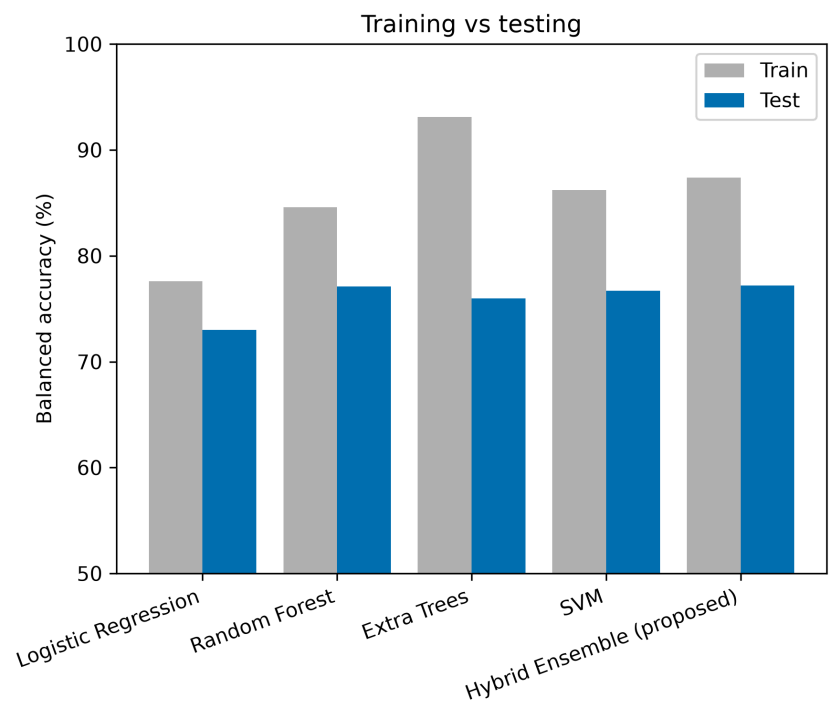


Figure 3: ধূসর = training, নীল = testing (Task 21)

১০.৬ ROC Curve

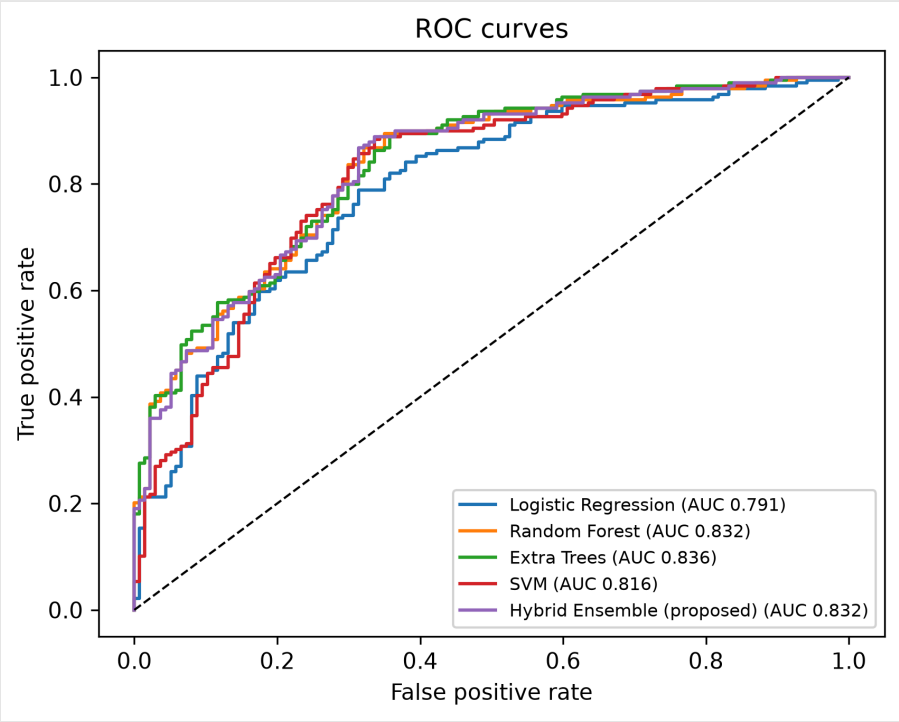


Figure 4: ৫টা model-এর ROC curve (Task 25)

Curve যত উপরে-বামে, model তত ভালো। Tree model ও Hybrid প্রায় একই লাইনে; Logistic Regression একটু নিচে। এই figure একবারের 5-fold run থেকে, তাই এখানে AUC (~০.৮৩) table-এর ৫০ বারের গড় (০.৮৪৩) থেকে একটু কম।

১০.৭ Confusion Matrix (Hybrid Ensemble)

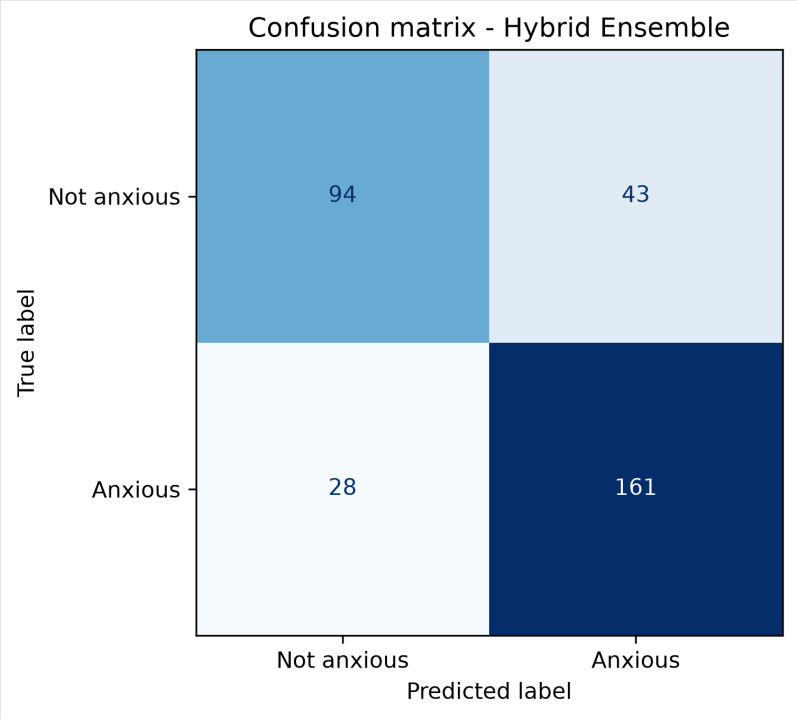


Figure 5: Hybrid-এর confusion matrix, ৩২৬ জন (Task 26)

ঘর	সংখ্যা	মানে
TP (ঠিক ধরেছে)	১৬১	১৮৯ জন anxious-এর মধ্যে ১৬১ জন ধরা পড়েছে (৮৫%)
FN (miss)	২৮	২৮ জন anxious ধরা পড়েনি
TN (ঠিক বাদ)	৯৪	১৩৭ জন not anxious-এর মধ্যে ৯৪ জন ঠিক বাদ (৬৯%)
FP (ভুল alarm)	৪৩	৪৩ জনকে ভুল করে anxious বলা হয়েছে

Screening-এ miss করা (FN) ভুল alarm (FP)-এর চেয়ে বেশি ক্ষতিকর। Hybrid miss কম করে (মাত্র ২৮ জন), তাই screening-এর জন্য এটা ভালো দিক।

১১. Validity Check: Leakage, Calibration, Fairness, Sample Size

এক কথায়: Duplicate রাখলে result ভুয়াভাবে ৯৮.৮% হয়। Probability-গুলো নির্ভরযোগ্য। কম বয়সী group-এ model একটু দুর্বল। আর data size একটু কম।

১১.১ Leakage Check (Task 30–32)

Data	Random Forest Accuracy (২০ বার split-এর গড়)	Test row-এর কত % training-এ আছে
Duplicate রেখে (১,৫০৩ row)	**৯৮.৮%**	৯৪.8%
Duplicate বাদ দিয়ে (৩২৬ row)	**৭৬.০%**	০%
পার্থক্য	**+২২.৮ point (ভুয়া)**	

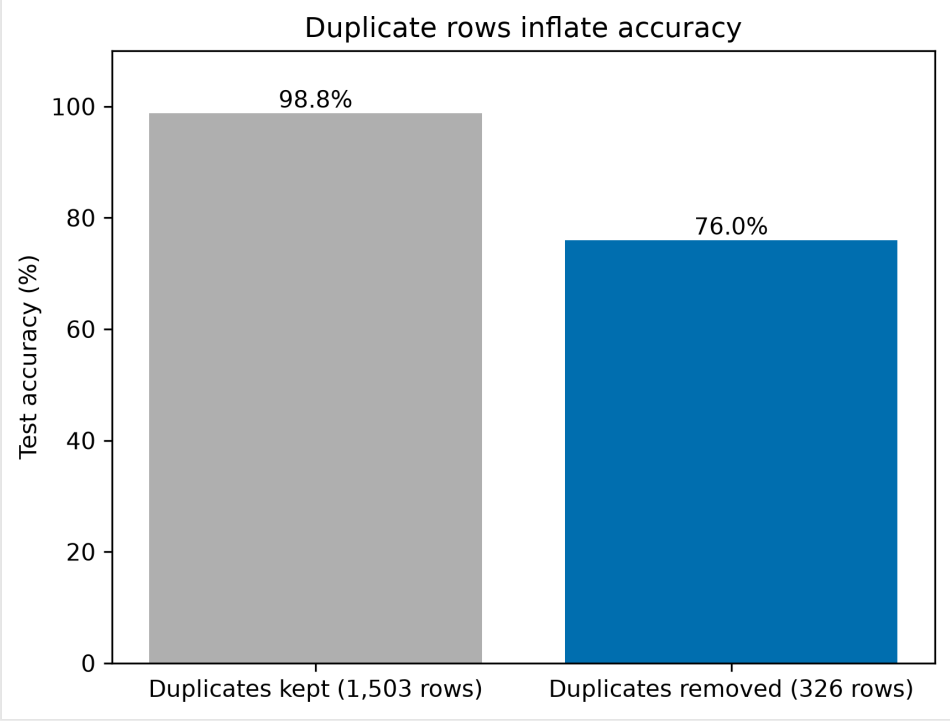


Figure 6: Duplicate row accuracy-কে কৃত্রিমভাবে বাড়িয়ে দেয় (Task 32)

এটাই এই project-এর সবচেয়ে শক্তিশালী message: একই dataset-এ প্রকাশিত ৯৬.৯৯% accuracy সম্ভবত এই duplicate-এর কারণে।

১১.২ Calibration (Task 27)

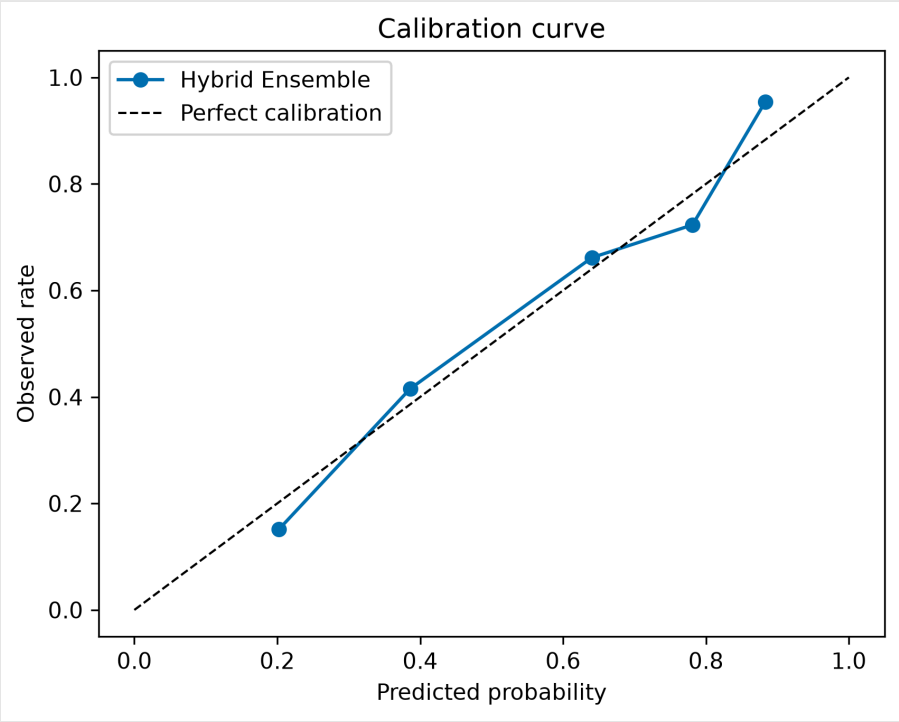


Figure 7: Hybrid-এর calibration curve

Check	Result	মানে
Calibration curve	Diagonal-এর কাছাকাছি	Model "৭০%" বললে বাস্তবেও প্রায় ৭০% anxious
Brier score (Hybrid)	০.১৬৩	কম = ভালো
Brier score (শুধু ৫৮% অনুমান করলে)	০.২৪৪	Model এর চেয়ে অনেক ভালো

১১.৩ Fairness: বয়স অনুযায়ী (Task 28)

Age Group	কতজন	Hybrid Balanced Accuracy	মন্তব্য
25–30	৪৯	৬৫.৬%	সবচেয়ে দুর্বল
30–35	**৭১**	**৮৩.৭%**	**সবচেয়ে ভালো**
35–40	৭৬	৭৮.০%	গড়ের উপরে
40–45	৭৩	৭৭.৩%	গড়ের কাছাকাছি
45–50	৫৭	৭৩.২%	গড়ের নিচে

কম বয়সী মায়েদের (25–30) জন্য model দুর্বল। তবে প্রতিটা group-এ মাত্র ৪৯–৭৬ জন, তাই এটা পাকা প্রমাণ না — শুধু একটা পর্যবেক্ষণ। Age-ই data-তে একমাত্র demographic তথ্য।

১১.৪ Sample Size (Task 29)

$$\text{প্রয়োজনীয় row} = (1.96 / 0.05)^2 \times 0.58 \times 0.42 \approx ৩৭৪$$

দরকার (Riley et al. 2020-এর সবচেয়ে সহজ শর্ত)	আছে	যথেষ্ট?
কমপক্ষে ৩৭৪ row	৩২৬ row	না

তাই result-গুলো "exploratory" — বড় dataset-এ আবার confirm করা দরকার।

১২. Explainable AI: SHAP ও LIME কীভাবে কাজ করে

> **এক কথায়:** Hybrid model একটা black box। SHAP ও LIME দেখায় কোন প্রশ্নের উত্তর model-কে "anxious" বলতে বেশি ঠেলে দিয়েছে।

১২.১ Setup (Task 33–35)

Step	কী করা হয়েছে
Data split	৮০% দিয়ে Hybrid train, বাকি ২০% (৬৬ জন) explain করা — এদের model আগে দেখেনি
Hold-out performance	এই ৬৬ জনে balanced accuracy ৭৭.৭%
Encoding	প্রতিটা উত্তরকে 0, 1, 2... code দেওয়া (`OrdinalEncoder`), যাতে ব্যাখ্যা **প্রশ্ন-ভিত্তিক** হয় (৯টা প্রশ্ন)
Predict function	Code থেকে আবার আসল উত্তরে ফিরিয়ে model-কে দেয়

১২.২ SHAP কীভাবে কাজ করে (Task 36–38)

SHAP game theory থেকে এসেছে। প্রতিটা প্রশ্নকে একজন "খেলোয়াড়" ধরা হয়। প্রশ্নটা যোগ করলে prediction গড়ে কতটা বদলায় — সেটাই তার অবদান।

$$\Phi_j = \Sigma_{S \subseteq F \setminus \{j\}} \left[|S|!(|F|-|S|-1)! \,/\, |F|! \right] \cdot \left[f(S \cup \{j\}) - f(S) \right]$$

Setting	মান	কেন
Algorithm	Exact	৯টা প্রশ্নে $২^৯$ = ৫১২টা combination — পুরোটা হিসাব সম্ভব
Background data	৫০টা training row	"প্রশ্ন না থাকলে" কী হতো, তা বোঝাতে
বিশেষ গুণ	সব প্রশ্নের SHAP যোগ = prediction − গড়	হিসাব নিখুঁত মেলে

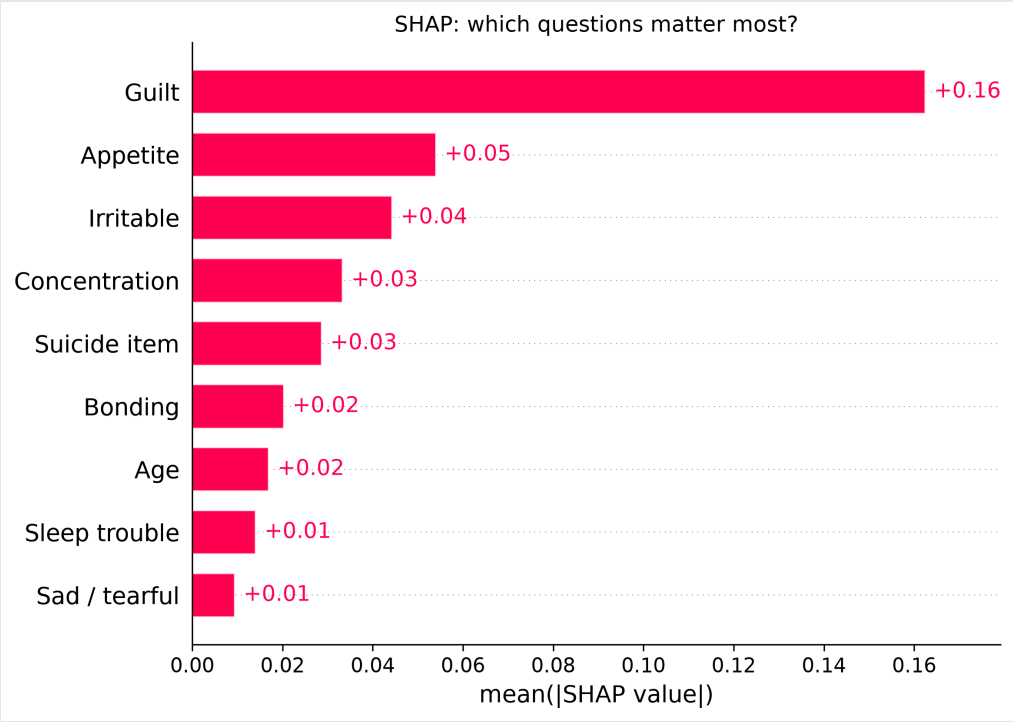


Figure 8: SHAP অনুযায়ী প্রতিটা প্রশ্নের গড় গুরুত্ব (Task 37)

১২.৩ একজন মায়ের SHAP ব্যাখ্যা

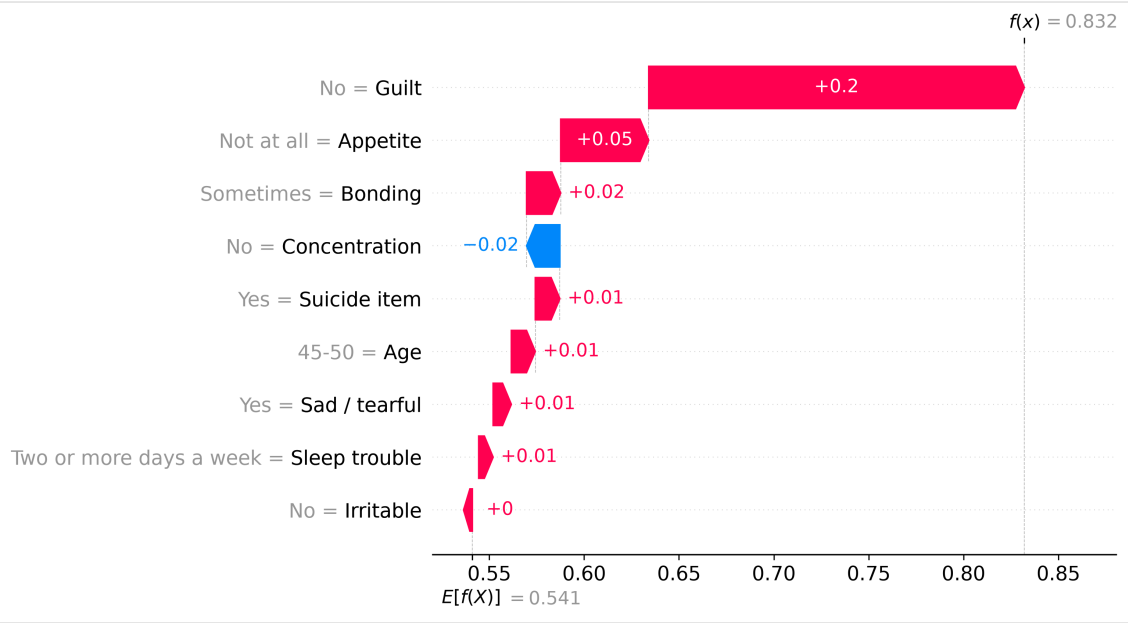


Figure 9: Test set-এর প্রথম anxious মায়ের SHAP waterfall (Task 38)

উত্তর	প্রভাব	মানে
Guilt = No	+০.২০	Anxious-এর সম্ভাবনা সবচেয়ে বেশি বাড়িয়েছে
Appetite = Not at all	+০.০৫	একটু বাড়িয়েছে
Bonding = Sometimes	+০.০২	সামান্য বাড়িয়েছে
Concentration = No	−০.০২	সামান্য কমিয়েছে
শুরু → শেষ	০.৫৪ → ০.৮৩	Model তাকে anxious বলেছে — যা সঠিক

১২.8 LIME কীভাবে কাজ করে (Task 39–41)

LIME একজন মানুষের উত্তরের আশেপাশে ২,০০০টা নকল উত্তর বানায়। Model-কে দিয়ে এগুলো predict করায়। তারপর একটা সহজ linear model বসিয়ে দেখে কোন উত্তর কতটা প্রভাব ফেলছে।

$$\xi(x) = \text{argmin}_g \, L(f, g, \pi_x) + \Omega(g)$$

f = Hybrid model, g = সহজ linear model, π_x = কাছের নমুনাকে বেশি গুরুত্ব, Ω = model সহজ রাখার শর্ত।

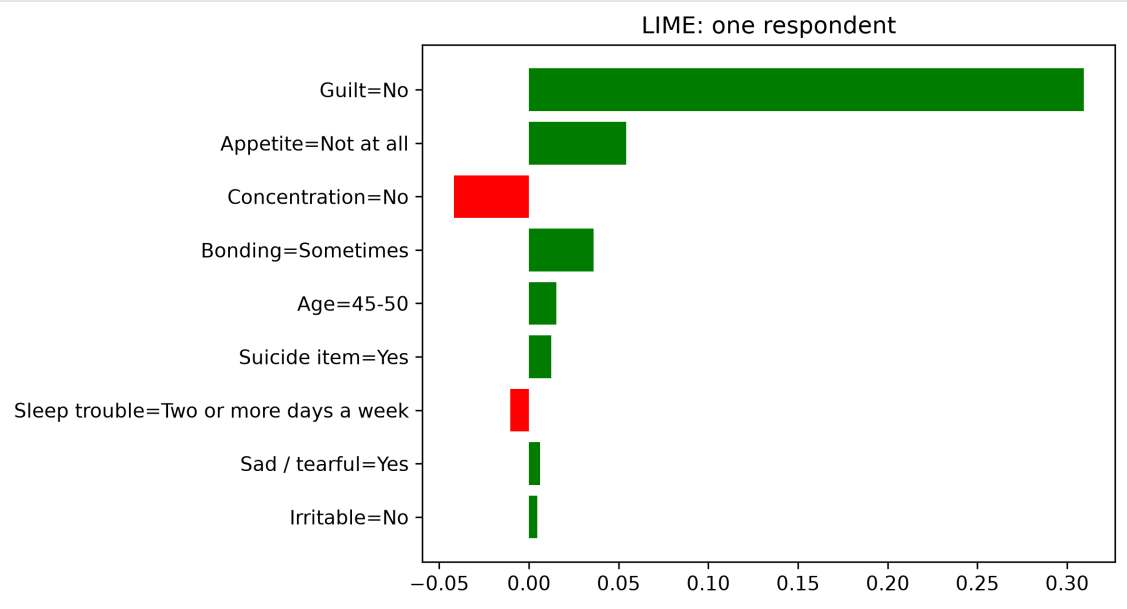


Figure 10: একই মায়ের LIME ব্যাখ্যা — সবুজ = বাড়ায়, লাল = কমায় (Task 40)

LIME-ও একই কথা বলে: Guilt = No সবচেয়ে বড় প্রভাব, তারপর Appetite। Concentration = No একটু কমায়। SHAP-এর সাথে প্রায় হুবহু মেলে।

১৩. SHAP vs LIME: পূর্ণ Comparison

এক কথায়: দুইটাই একই গল্প বলে (মিল ৯৮%)। SHAP বেশি নিখুঁত, LIME প্রায় ৫ গুণ দ্রুত।

১৩.১ প্রশ্ন অনুযায়ী Importance (Task 42–43)

Rank	প্রশ্ন	SHAP (%)	LIME (%)	Rank মিলেছে?
১	**Guilt (অপরাধবোধ)**	**৪২.৪**	**৪৭.৬**	✅
২	Appetite (খাওয়া)	১৪.১	১৩.৪	✅
৩	Irritable (খিটখিটে)	১১.৫	১০.৪	✅
৪	Concentration (মনোযোগ)	৮.৭	৭.৭	LIME-এ ৫
৫	Suicide item	৭.৫	৮.৪	LIME-এ ৪
৬	Bonding	৫.৩	৫.০	✅
৭	Age	৪.৪	৩.৯	✅
৮	Sleep trouble	৩.৭	২.২	✅
৯	Sad / tearful	২.৫	১.৩	✅

৯টার মধ্যে ৭টা প্রশ্নের rank হুবহু মিলেছে। শুধু ৪ ও ৫ নম্বর জায়গা বদল করেছে।

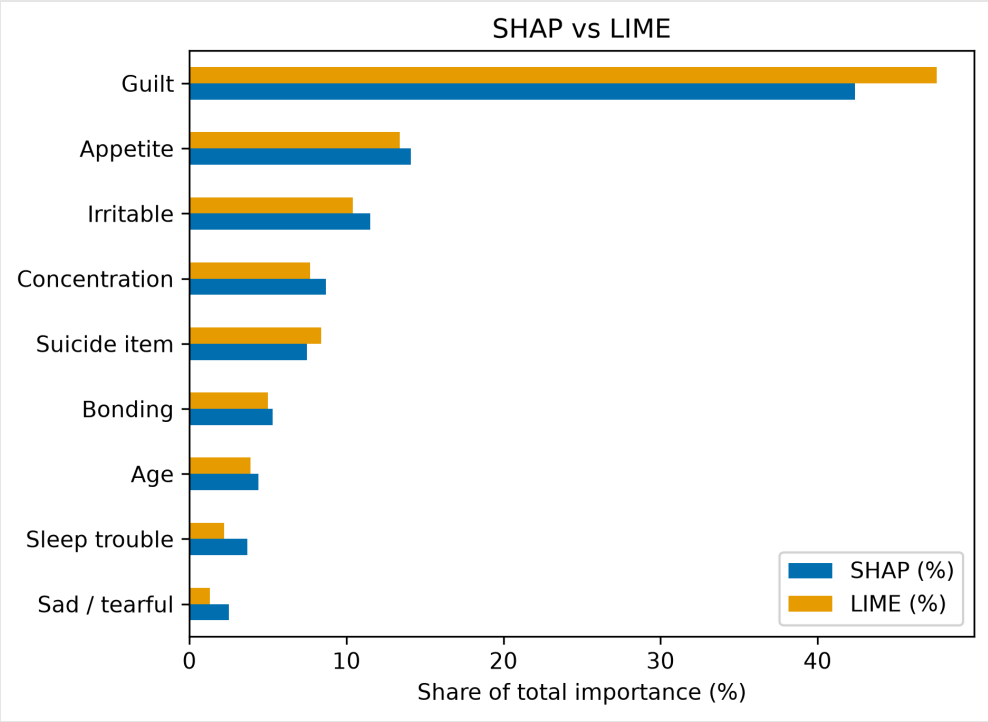


Figure 11: SHAP (নীল) ও LIME (কমলা) পাশাপাশি (Task 43)

১৩.২ সংখ্যায় মিল ও গতি (Task 44)

Measure	Result	সহজ মানে
Global rank agreement (Spearman)	০.৯৮৩	প্রশ্নের importance-এর ক্রম প্রায় হুবহু এক
Top-3 প্রশ্ন একই	৩ / ৩	Guilt, Appetite, Irritable — দুইটাতেই
প্রতি মানুষে rank মিল (গড়)	০.৭৩৪	ব্যক্তি পর্যায়ে মিল ভালো, তবে নিখুঁত না
প্রতি মানুষে top প্রশ্ন একই	৮৪.৮%	৬৬ জনের ৫৬ জনে একই
সময় / মানুষ — SHAP	০.৪৪ সেকেন্ড	ধীর, কারণ ৫১২টা combination
সময় / মানুষ — LIME	০.০৯ সেকেন্ড	প্রায় ৫ গুণ দ্রুত

১৩.৩ Theory-র দিক থেকে Comparison

দিক	SHAP	LIME	এই project-এ জয়ী
ভিত্তি	Game theory (Shapley value)	Local linear model	—
Accuracy of explanation	Exact (নিখুঁত)	আনুমানিক (approximation)	SHAP
যোগফল prediction-এর সাথে মেলে?	হ্যাঁ	নিশ্চিত না	SHAP
Randomness	কম (শুধু background)	বেশি (নকল নমুনা)	SHAP
Speed	০.৪৪ s	০.০৯ s	LIME
অনেক feature হলে	খুব ধীর হয়ে যায়	দ্রুত থাকে	LIME
বোঝা সহজ?	Waterfall চার্ট পরিষ্কার	Bar চার্ট সহজ	দুটোই

১৩.৪ কখন কোনটা ব্যবহার করবেন

পরিস্থিতি	পরামর্শ
Feature কম (এই project-এর মতো ৯টা), নিখুঁত ব্যাখ্যা দরকার	SHAP
Feature অনেক বেশি, বা দ্রুত ব্যাখ্যা দরকার	LIME
Research-এ বিশ্বাসযোগ্যতা বাড়াতে	দুইটাই ব্যবহার করে মিলিয়ে দেখা (এই project যা করেছে)

১৩.৫ Explanation থেকে কী শিখলাম

পর্যবেক্ষণ	এর মানে
Guilt একাই ৪২–৪৮% importance	Model একটা প্রশ্নের উপর অনেক বেশি নির্ভর করে; Guilt বাদ দিলে আগের test-এ সব model প্রায় ৬০%-এ নেমে যায়
"Guilt = No" anxiety বাড়ায়	Clinically উল্টো — data-তে সমস্যা আছে, model-এর দোষ না
Sad/tearful প্রায় গুরুত্বহীন	বাস্তব data-তে অপ্রত্যাশিত — data quality নিয়ে আরেকটা প্রশ্ন
দুই আলাদা পদ্ধতি একই কথা বলে	Explanation-গুলো বিশ্বাসযোগ্য

১৪. Literature Review ও অন্য Research-এর সাথে Comparison

এক কথায়: অন্য research আলাদা data ও আলাদা target ব্যবহার করেছে, তাই সংখ্যা সরাসরি তুলনা করা যায় না। কিন্তু একই dataset-এর ৯৭% দাবি আমাদের leakage test দিয়ে ব্যাখ্যা করা যায়।

১৪.১ Related Research Table

Study	Data	Target	Method	Result
Zhang W et al. 2020 (JMIR Med Inform)	China, ৫০৮ জন	PPD	SVM, RF	AUC ০.৭৮
Shin et al. 2020 (J Clin Med)	USA PRAMS, ২৮,৭৫৫	PHQ-2	৯টা algorithm	—
Hochman et al. 2021 (Depress Anxiety)	Israel EHR, ২,১৪,৩৫৯	নতুন PPD	Gradient boosting	—
Amit et al. 2021 (BMC Pregnancy Childbirth)	UK EHR, ২,৬৬,৫৪৪	PPD diagnosis	ML on EHR	AUC ০.৭২–০.৭৪
Andersson et al. 2021 (Sci Rep)	Sweden	৬ সপ্তাহে depression	Multiple ML	—
Saqib et al. 2021 (Review)	১৪টা study	PPD	Review	AUC ০.৭৮–০.৯৩
Cellini et al. 2022 (Review)	১১টা study	PPD	Review	সব AUC > ০.৭
Nakamura et al. 2024	Japan	১ মাসে depression	Gradient boosting	AUC ০.৮৩
Huang et al. 2025 (Front Med)	Clinical cohort	PPD	৮টা algorithm + XAI	AUC ০.৯৫৫
Raisa et al. 2022	Bangladesh, ১৫০	PPD	RF	AUC ৯৮%
Adhikari & Karki 2026	Bangladesh, ৮০০	৩টা EPDS level	LR, RF, XGB, Voting, SHAP	Accuracy ৭৬.৫–৭৭.৪%
Nayee et al. 2026 (ICSUMMIT)	Kaggle ১,৫০৩ (সম্ভবত এই dataset)	উল্লেখ নেই	SVM, XGB, RF, DT	Accuracy ৯৬.৯৯%
This study (Hybrid)	**৩২৬ unique row**	**Self-reported anxiety**	**Hybrid + SHAP/LIME**	**Bal. acc. ৭৭.২%, AUC ০.৮৪৩**

১৪.২ একই Dataset-এ সরাসরি Comparison

Study	Duplicate?	Testing	Result	বিশ্বাসযোগ্য?
Nayee et al. 2026	রাখা (উল্লেখ নেই)	একবার split	৯৬.৯৯%	সন্দেহজনক
আমাদের leakage test	রাখা	২০ বার split	৯৮.৮%	না — ইচ্ছা করে ভুল দেখানো
আমাদের leakage test	বাদ	২০ বার split	৭৬.০%	হ্যাঁ
This study (Hybrid)	**বাদ**	**৫০ বার CV**	**৭৭.২% (balanced)**	**হ্যাঁ**

১৪.৩ Typical Research বনাম এই Study

Typical research-এ যা হয়	এই study-তে যা করা হয়েছে
একবার train/test split	৫০ বার test, corrected CI
Duplicate check হয় না	Full audit ও leakage-এর পরিমাপ
"Ensemble best" ধরে নেওয়া হয়	Statistical test দিয়ে যাচাই, সৎ report
SHAP একবার plot করা হয়	SHAP vs LIME সংখ্যা দিয়ে comparison
Test result দেখে model বাছাই	আলাদা run-এ বাছাই, পরে confirm
Limitation কম লেখা হয়	১০টা limitation পরিষ্কারভাবে লেখা

> অন্য research-এর সংখ্যার সাথে "আমাদের result বেশি ভালো" — এমন দাবি করবেন না। Data ও target আলাদা, তাই এগুলো শুধু প্রেক্ষাপট (context)।

১৫. Limitation (সীমাবদ্ধতা)

এক কথায়: বড় সমস্যা data নিয়ে — target দুর্বল, data ছোট, source অজানা। Model-এর সমস্যা কম।

#	Limitation	প্রভাব কতটা	কীভাবে সমাধান করা যায়
১	Target মাত্র একটা self-reported প্রশ্ন (GAD-7/EPDS না)	বেশি	Validated scale সহ dataset
২	সব প্রশ্ন একই সময়ে (cross-sectional) — "early" প্রমাণ করা যায় না	বেশি	Longitudinal data (গর্ভাবস্থা থেকে follow-up)
৩	Data ছোট: ৩২৬ row, দরকার ৩৭৪+	বেশি	বড় dataset
৪	Data-র source, ethics, license অজানা	বেশি	Kaggle page-এ license check; অন্য dataset
৫	Guilt-এর উল্টো সম্পর্ক, একটা প্রশ্নের আধিপত্য	মাঝারি	ভালো মানের data
৬	External validation নেই	মাঝারি	দ্বিতীয় dataset-এ test
৭	Hybrid-এর সুবিধা significant না; overfitting gap ১০ point	মাঝারি	বড় data-তে আবার test
৮	Hyperparameter tuning করা হয়নি	কম	Nested cross-validation
৯	Fairness শুধু বয়সে	কম	আরও demographic তথ্যসহ data
১০	SHAP/LIME model কী শিখেছে দেখায়, আসল কারণ না	কম	Clinical expert-এর সাথে যাচাই

১৬. Research Gap ও Future Work

এক কথায়: ৫টা gap এই project পূরণ করেছে। আরও ৬টা gap ভবিষ্যৎ research-এর জন্য খোলা।

১৬.১ যে Gap এই Project পূরণ করেছে

Gap	কোন research-এ দেখা গেছে	এই project-এর সমাধান
G1: Public survey data-য় duplicate/leakage check হয় না	Alkhateeb 2026 review; Nayee 2026	Audit + leakage measurement
G2: ছোট study-তে একবার split	Zhang 2020, Huang 2025, Raisa 2022	৫০ বার CV + corrected CI
G3: Ensemble best ধরে নেওয়া হয়	Adhikari & Karki 2026	Statistical test, সৎ report
G4: XAI শুধু plot, মাপা হয় না	Huang 2025 ইত্যাদি	SHAP vs LIME agreement ও speed মাপা
G5: একটা feature-এর আধিপত্য লুকানো থাকে	Adhikari & Karki (PHQ-9)	XAI দিয়ে Guilt-এর আধিপত্য প্রকাশ

১৬.২ যে Gap এখনো খোলা (Future Work)

#	Future Work	কেন দরকার	অগ্রাধিকার
১	Validated label (EPDS) সহ দ্বিতীয় dataset-এ test (যেমন Bangladesh Mendeley dataset, ৮০০ জন)	External validation, journal-এর জন্য সবচেয়ে জরুরি	সবচেয়ে বেশি
২	Longitudinal data	তখনই "early screening" দাবি করা যাবে	বেশি
৩	Nested hyperparameter tuning ও decision curve analysis	Model আরও মজবুত, clinical উপকারিতা মাপা	মাঝারি
৪	বড় পরিসরে fairness (আয়, গ্রাম/শহর, delivery type)	সব group-এ model সমান কি না	মাঝারি
৫	বিভিন্ন data split-এ SHAP/LIME stability	Explanation কতটা স্থির	মাঝারি
৬	Doctor-দের দিয়ে SHAP বনাম LIME মূল্যায়ন	কোন explanation বেশি বোঝা যায় ও বিশ্বাস হয়	কম

> দ্বিতীয় dataset ব্যবহার করলে সাবধান: PHQ-9 বা EPDS-এর মতো screening score-কে feature হিসেবে দেবেন না, তাহলে আবার leakage হবে।

১৭. Ethics ও Reporting (TRIPOD+AI)

> **এক কথায়:** Analysis-এর বেশিরভাগ reporting শর্ত পূরণ হয়েছে। বাকি: data license, source ও কিছু declaration।

১৭.১ Ethics

বিষয়	কী করতে হবে
Sensitive data	আত্মহত্যা-সংক্রান্ত প্রশ্ন আছে; এর হারকে clinical prevalence হিসেবে দেখানো যাবে না
Clinical use	Model কোনো ব্যক্তির diagnosis-এর জন্য না
License	Kaggle page-এ check করে `data/DATA_CARD.md` -তে লিখতে হবে
Secondary use	Thesis-এ ethics statement দিতে হবে

১৭.২ TRIPOD+AI Checklist-এর অবস্থা

অংশ	অবস্থা
Data preparation, missing value, preprocessing	✅ সম্পূর্ণ
Model building, validation, CI	✅ সম্পূর্ণ
Class imbalance, fairness, sample size	✅ সম্পূর্ণ
Explainability (SHAP, LIME)	✅ সম্পূর্ণ
Calibration	✅ curve ও Brier; decision curve বাকি
Data source, participants, license	❌ source থেকে পাওয়া যায় না
Funding, conflict of interest, open science	🟡 declaration যোগ করতে হবে

বিস্তারিত: `research_plan/10_tripod_ai_checklist.md`

১৮. Conclusion: Thesis-এ কী লিখবেন

এক কথায়: Hybrid Ensemble overall best (৭৭.২%), SHAP ও LIME একমত, আর প্রকাশিত ৯৭% result সম্ভবত duplicate leakage-এর ফল।

১৮.১ মূল Finding

#	Finding	প্রমাণ
১	Hybrid Ensemble overall rank ১	Balanced accuracy ৭৭.২%, AUC ০.৮৪৩
২	কিন্তু পার্থক্য significant না	সব corrected p > ০.০৫
৩	Guilt সবচেয়ে important প্রশ্ন	SHAP ৪২.৪%, LIME ৪৭.৬%
৪	SHAP ও LIME একমত	Spearman ০.৯৮৩, top-3 একই
৫	Duplicate result-কে ভুয়াভাবে বাড়ায়	৭৬.০% → ৯৮.৮%
৬	Probability নির্ভরযোগ্য	Brier ০.১৬৩

১৮.২ Thesis-এর জন্য এক বাক্যে

> "Leakage-free evaluation-এ একটি Hybrid Ensemble (RF + ET + SVM) postpartum anxiety symptom প্রায় ৭৭% balanced accuracy-তে শনাক্ত করে; SHAP ও LIME দুটোই এর সিদ্ধান্ত একইভাবে ব্যাখ্যা করে; এবং একই dataset-এ প্রকাশিত অতি-উচ্চ accuracy সম্ভবত duplicate row-এর leakage থেকে এসেছে।"

১৮.৩ Do's and Don'ts

✅ লিখুন	❌ লিখবেন না
"Hybrid overall rank-এ ১ নম্বর"	"Hybrid সবার চেয়ে significantly better"
"Symptom screening support"	"Diagnosis" বা "Depression detection"
"Self-reported anxiety item"	"Anxiety disorder"
"অন্য study আলাদা data ব্যবহার করেছে"	"আমাদের result অন্যদের চেয়ে ভালো"
"Exploratory result, বড় data-তে confirm দরকার"	"Clinically ready model"

Appendix A: Notebook-এর ৪৭টি Task

File: `notebooks/final_thesis_study.ipynb` — প্রতিটা Task একটা আলাদা cell, শুরুতে `# Task N:` comment।

Task	কাজ	Task	কাজ
1	Library import	25	Figure: ROC curve
2	Settings (path, seed, color)	26	Figure: Confusion matrix
3	Dataset load	27	Figure: Calibration + Brier
4	Duplicate গণনা	28	Fairness: বয়স অনুযায়ী
5	Duplicate বাদ	29	Sample size check
6	X ও y আলাদা	30	Leakage check (২০ split)
7	Figure: Class balance	31	Copy হওয়া test row-এর %
8	Preprocessing	32	Figure: Leakage-এর প্রভাব
9	Logistic Regression	33	XAI: 80/20 split ও training
10	Random Forest	34	উত্তরকে number-এ রূপান্তর
11	Extra Trees	35	SHAP/LIME-এর predict function
12	SVM	36	SHAP value হিসাব
13	Hybrid Ensemble	37	Figure: SHAP importance
14	৫টা model একসাথে	38	Figure: একজনের SHAP
15	Evaluation metric	39	LIME explanation
16	৫০ বার train ও test	40	Figure: একজনের LIME
17	Test result table	41	LIME weight table
18	95% CI	42	SHAP vs LIME importance
19	Training vs testing	43	Figure: SHAP vs LIME
20	Figure: Model comparison	44	Agreement ও speed
21	Figure: Train vs test	45	Final comparison ১: Model
22	Statistical test	46	Final comparison ২: SHAP vs LIME
23	Overall ranking	47	Final comparison ৩: Literature
24	Out-of-fold probability		

Appendix B: Figure ও Result File-এর তালিকা

Figure (results/final/)

#	File	কী দেখায়	Task	এই বইয়ে
1	fig01_class_balance.png	Anxious বনাম Not anxious	7	অধ্যায় ৪
2	fig02_model_comparison.png	৫টা model-এর balanced accuracy	20	অধ্যায় ১০
3	fig03_train_vs_test.png	Training বনাম testing	21	অধ্যায় ১০
4	fig04_roc_curves.png	ROC curve	25	অধ্যায় ১০
5	fig05_confusion_matrix.png	Hybrid-এর confusion matrix	26	অধ্যায় ১০
6	fig06_calibration.png	Calibration curve	27	অধ্যায় ১১
7	fig07_leakage.png	Duplicate-এর প্রভাব	32	অধ্যায় ১১
8	fig08_shap_importance.png	SHAP importance	37	অধ্যায় ১২
9	fig09_shap_one_person.png	একজনের SHAP	38	অধ্যায় ১২
10	fig10_lime_one_person.png	একজনের LIME	40	অধ্যায় ১২
11	fig11_shap_vs_lime.png	SHAP vs LIME	43	অধ্যায় ১৩

Result Table (CSV)

File	কী আছে
test_results.csv	৫টা model-এর ৭টা metric
balanced_accuracy_ci.csv	95% confidence interval
train_vs_test.csv	Training, testing ও gap
statistical_tests.csv	Hybrid vs বাকিরা
ranking.csv	Overall rank
fairness_by_age.csv	বয়স অনুযায়ী result
leakage_check.csv	Duplicate রেখে বনাম বাদ দিয়ে
shap_vs_lime_importance.csv	প্রশ্ন অনুযায়ী importance
shap_vs_lime_agreement.csv	মিল ও speed
final_model_comparison.csv	Final table ১
final_shap_vs_lime.csv	Final table ২
final_literature_comparison.csv	Final table ৩

Appendix C: Glossary (শব্দের সহজ অর্থ)

English term	সহজ বাংলা মানে
Dataset	Data-র table
Feature	Input প্রশ্ন বা column
Target / Label	যেটা predict করতে চাই (এখানে: anxious কি না)
Training / Testing	শেখানো / পরীক্ষা করা
Data leakage	Test-এর তথ্য training-এ ঢুকে যাওয়া, result ভুয়া ভালো দেখায়
Duplicate	হুবহু একই row একাধিকবার
Cross-validation (CV)	Data ভাগ করে পালাক্রমে train ও test
Fold	CV-র একটা ভাগ
Overfitting	Model মুখস্থ করে ফেলে, নতুন data-তে খারাপ করে
One-hot encoding	প্রতিটা উত্তরকে আলাদা 0/1 column বানানো
Imputation	ফাঁকা ঘর পূরণ
Hyperparameter	Model-এর setting (যেমন কয়টা tree)
Ensemble / Hybrid	একাধিক model মিলিয়ে একটা model
Soft voting	সব model-এর probability-র গড়
Threshold	যে মানের উপরে হলে "Anxious" বলা হয় (এখানে 0.5)
Balanced accuracy	দুই group-কে সমান গুরুত্ব দিয়ে accuracy
Sensitivity / Specificity	Anxious ধরার হার / Not anxious ঠিক বাদের হার
ROC-AUC	Model-এর আলাদা করার ক্ষমতা (0.5–1)
Confidence interval (CI)	আসল মান যে range-এ থাকার সম্ভাবনা বেশি
p-value / Significant	পার্থক্য কাকতালীয় কি না; $p < 0.05$ হলে "significant"
Calibration	Model-এর probability বাস্তবের সাথে মেলে কি না
Explainable AI (XAI)	Model-এর সিদ্ধান্ত মানুষকে বোঝানো
SHAP / LIME	দুটো জনপ্রিয় XAI পদ্ধতি
Spearman correlation	দুইটা ranking কতটা মেলে (−1 থেকে 1)
Out-of-fold prediction	এমন model-এর prediction, যে ওই row কখনো দেখেনি

Appendix D: Software ও References

Software

Software	Version (.venv)
Python	3.11
NumPy / pandas / SciPy	2.4.6 / 3.1.0 / 1.17.1
scikit-learn / matplotlib	1.9.1 / 3.11.2
SHAP / LIME	0.51.0 / 0.2.0.1

Anaconda environment (Python 3.14)-এও পুরো notebook একই result দেয়, শুধু সময়ের মান একটু আলাদা। Random seed = 42। চালানোর নিয়ম: `pip install -r requirements.txt` → notebook খুলে Run All (প্রায় ১ মিনিট)।

References

1. Collins GS et al. TRIPOD+AI statement. BMJ 2024;385:e078378.
2. Riley RD et al. Calculating the sample size required for developing a clinical prediction model. BMJ 2020;368:m441.
3. Nayee N, Shah S, Bhaidasna H. Machine Learning-Based Diagnosis of Postpartum Depression Methods and Insights. ICSUMMIT 2026, Atlantis Press, pp. 254–265. doi:10.2991/978-94-6239-727-9_19.
4. Zhang W, Liu H, Silenzio VMB, Qiu P, Gong W. Machine Learning Models for the Prediction of Postpartum Depression. JMIR Med Inform 2020;8(4):e15516.
5. Shin D, Lee KJ, Adeluwa T, Hur J. Machine Learning-Based Predictive Modeling of Postpartum Depression. J Clin Med 2020;9(9):2899.
6. Hochman E et al. Development and validation of a machine learning-based postpartum depression prediction model. Depress Anxiety 2021;38(4):400–411.
7. Amit G et al. Estimation of postpartum depression risk from electronic health records using machine learning. BMC Pregnancy Childbirth 2021;21:630.
8. Andersson S et al. Predicting women with depressive symptoms postpartum with machine learning methods. Sci Rep 2021;11:7877.
9. Saqib K, Khan AF, Butt ZA. Machine Learning Methods for Predicting Postpartum Depression: Scoping Review. JMIR Ment Health 2021;8(11):e29838.
10. Cellini P et al. Machine learning in the prediction of postpartum depression: A review. J Affect Disord 2022;309.
11. Nakamura Y et al. Early identification of postpartum depression using machine learning. Psychiatry Clin Neurosci 2024. doi:10.1111/pcn.13659.
12. Huang X et al. Postpartum depression risk prediction using explainable machine learning algorithms. Front Med 2025. doi:10.3389/fmed.2025.1565374.

13. Xia J et al. Artificial intelligence-oriented predictive model for the risk of postpartum depression: a systematic review. Front Public Health 2025.
14. Alkhateeb et al. AI for Detecting and Predicting Postpartum Depression: Scoping Review. J Med Internet Res 2026;28:e77376.
15. Ruger-Navarrete A et al. AI in the prevention and early detection of postpartum depression: systematic review and meta-analysis. Front Psychiatry 2026.
16. Kim H. Predictive Analysis of Postpartum Depression Using Machine Learning. Healthcare 2025;13(8):897.
17. Raisa JF, Kaiser MS, Mahmud M. A Machine Learning Approach for Early Detection of Postpartum Depression in Bangladesh. Brain Informatics 2022, Springer.
18. Adhikari, Karki. Machine Learning Based Postpartum Depression Risk Prediction: A Case Study on a Bangladeshi Dataset. Islington J Multidiscip Res 2026.
19. Lundberg SM, Lee SI. A Unified Approach to Interpreting Model Predictions (SHAP). NeurIPS 2017.
20. Ribeiro MT, Singh S, Guestrin C. "Why Should I Trust You?" (LIME). KDD 2016.
21. Nadeau C, Bengio Y. Inference for the Generalization Error. Machine Learning 2003.

দ্রষ্টব্য: Reference ১৯–২১-এর বিস্তারিত এই project-এ আলাদা করে verify করা হয়নি; thesis-এ দেওয়ার আগে মিলিয়ে নিন।