প্রজেক্ট রিপোর্ট: CGTH দিয়ে প্রসবোত্তর উদ্বেগের লক্ষণ স্ক্রিনিং

Interpretable Postpartum Anxiety Symptom Screening Using Confidence-Gated Hybrid Machine Learning
রিপোজিটরি: research-projects · তৈরি: ২০২৬-১১-০২

১. এক নজরে প্রজেক্ট

বিষয়	বিবরণ
ডেটা	Kaggle-এর "PostPartum Depression" ডেটাসেট: ১,৫০৩ সারি, ১১ কলাম
টার্গেট	`Feeling anxious` (Yes/No), একটি স্ব-রিপোর্টেড প্রশ্ন
প্রস্তাবিত পদ্ধতি	**CGTH (Confidence-Gated Transparent Hybrid)**: Logistic Regression ও Random Forest-এর ছোট হাইব্রিড
মূল ফলাফল	CGTH-এর balanced accuracy ০.৭৫৭, RF-এর ০.৭৬১, LR-এর ০.৭৩০। CGTH-এর ৬৮% সিদ্ধান্ত স্বচ্ছ LR নিয়েছে
ধরন	পদ্ধতিগত ও অনুসন্ধানমূলক (exploratory) থিসিস প্রজেক্ট। ক্লিনিক্যাল টুল নয়

২. কেন করা হয়েছে

1. **মূল সমস্যা:** সরল মডেল (LR) ব্যাখ্যা করা সহজ কিন্তু কম নির্ভুল। জটিল মডেল (RF) বেশি নির্ভুল কিন্তু ব্যাখ্যা করা কঠিন।
2. **প্রচলিত হাইব্রিডের দুর্বলতা:** Voting বা Stacking প্রতিটি কেসেই দুই মডেল মিশিয়ে দেয়, তাই কোনো একক সিদ্ধান্তই সহজে ব্যাখ্যাযোগ্য থাকে না।
3. **গবেষণার প্রশ্ন:** স্বচ্ছ মডেল বেশিরভাগ সিদ্ধান্ত নিলে কি জটিল মডেলের মতো নির্ভুলতা ধরে রাখা যায়?
4. **সাহিত্যের ফাঁক (৬টি):** ডেটার মান যাচাই (ডুপ্লিকেট, লেবেল) কম হয়; ছোট স্যাম্পলে শুধু একটি স্প্লিটের পয়েন্ট এস্টিমেট দেওয়া হয়; ব্যাখ্যাযোগ্যতা মাপা হয় না; ensemble ভালো ধরে নেওয়া হয়, পরীক্ষা হয় না; একটি প্রশ্নের উপর নির্ভরতা চাপা থাকে; "coverage" কেউ রিপোর্ট করে না।

৩. প্রজেক্ট কিভাবে বিবর্তিত হয়েছে

ধাপ ১: প্রথম প্রচেষ্টা (পুরনো নোটবুক)

- **1-project.ipynb** (Stage 1): বেসলাইন, LR ও RF, `LabelEncoder`, ৮০/২০ স্প্লিট।
- **2-project.ipynb** (Stage 2): SVM, Gradient Boosting, Soft-Voting যোগ; feature engineering ও patient screening ডেমো।
- **main-projects.ipynb**: ৫টি মডেলের তুলনা, confusion matrix, ROC-AUC।
- **c_project.ipynb** (৫৬ ধাপ): SMOTE, class weights, 10-fold CV, calibration, Brier score, learning curve, SHAP, McNemar test।

মূল শিরোনাম ছিল: "Early Screening and Risk Stratification of Postpartum Depression and Anxiety Using Explainable Ensemble ML: A Comparative Benchmark"।

ধাপ ২: ডেটা ও কোড অডিট

ডেটার সমস্যা:

- ১,৫০৩ সারির মধ্যে মাত্র **৩২৬টি ইউনিক** (৭৮% ডুপ্লিকেট)। মাত্র ৯০টি আলাদা টাইমস্ট্যাম্প; এক মিনিটে ৫১টি সাবমিশন, যা বাস্তবে অসম্ভব।
- ডুপ্লিকেট রেখে RF চালালে accuracy ০.৯৯৩; ডুপ্লিকেট বাদ দিলে প্রায় ০.৭৭। এই ফারাক পুরোটাই leakage।
- টার্গেট কোনো যাচাইকৃত স্কেল (EPDS/GAD-7) নয়, একটি প্রশ্নের উত্তর।
- **Guilt** প্রশ্নের সাথে anxiety-র সম্পর্ক উল্টো: Guilt = No হলে anxious-এর সম্ভাবনা ০.৮১, Guilt = Yes হলে ০.২০। ক্লিনিক্যালি অসম্ভাব্য।
- "Sad/Tearful"-এর সাথে anxiety-র কোনো সম্পর্ক নেই (Cramér's V = ০.০৫)।
- সময়ের তথ্য নেই, তাই "early" প্রমাণ করা যায় না।

কোডের সমস্যা:

- সব কলামে `cat.codes` ব্যবহারে nominal ক্যাটাগরিতে ভুল ক্রম আরোপ হয়েছে; LR-এর AUC ০.৭০৩ (one-hot-এ ০.৮০৫)।
- স্প্লিটের আগে imputation হয়েছে।
- একটি মাত্র স্প্লিট, টেস্ট সেটে ৬৬ সারি। ২০০ seed-এ RF-এর accuracy ০.৬৭ থেকে ০.৮৬ ওঠানামা করেছে।
- test result দেখে "best model" বাছা হয়েছে; কোনো confidence interval বা significance test ছিল না।

ধাপ ৩: স্কোপ ছোট করা

মূল শিরোনামের শব্দ	সমস্যা
Early	সময়ের তথ্য নেই
Depression	কোনো depression লেবেল নেই
Risk stratification	যাচাইয়ের মতো আউটকাম নেই
Ensemble (অবদান হিসেবে)	RF-কে ছাড়িয়ে যায়নি

পাঁচটি বিকল্প শিরোনাম থেকে **T1** বাছা হয়েছে, কারণ এতে নিজস্ব পদ্ধতি আছে, ডেটার সাথে মেলে এবং শুরুর গবেষকের জন্য সহজ।

ধাপ ৪: উদ্দেশ্য ও হাইপোথিসিস আগে ঠিক করা

- **H1:** CGTH, RF-এর তুলনায় non-inferior (margin ০.০৩ balanced accuracy)।
- **H2:** CGTH, LR-এর চেয়ে ভালো।
- RQ3–RQ6: coverage কত; gate কেন কাজ করে; ডুপ্লিকেটে কত ফোলে; guilt বাদ দিলে কী হয়।
- **প্রাইমারি মেট্রিক:** balanced accuracy, কারণ ক্লাস ৫৮/৪২ এবং CGTH একটি yes/no সিদ্ধান্ত-নিয়ম।

ধাপ ৫: মূল গবেষণা (cgth_hybrid_study.ipynb, ২৩ Task)

Task	কী করা হয়েছে
1–2	লাইব্রেরি ইমপোর্ট। সেটিংস আগেই স্থির: SEED = 42, δ = 0.2, margin = 0.03, δ গ্রিড ০–০.৫। লাইব্রেরি ভার্সন সেভ
3–5	CSV লোড (শুধু পড়া)। Timestamp ও exact duplicate বাদ, ফলে ৩২৬ সারি। `Feeling anxious = Yes` → y = 1
6	প্রিপ্রসেসিং: `SimpleImputer(most_frequent)` + `OneHotEncoder`, প্রতিটি ট্রেনিং ফোল্ডের ভেতরে শেখা (leakage নেই)
7	**CGTH নিয়ম:** $\|p_{LR} - 0.5\| \geq \delta$ হলে LR-এর সিদ্ধান্ত, নইলে RF-এর। তুলনার জন্য Soft Voting (গড়)
8	মেট্রিক: balanced accuracy, accuracy, sensitivity, specificity, F1, MCC, ROC-AUC, LR coverage
9	৫-ফোল্ড stratified CV × ১০ বার = ৫০ ফোল্ড; সব মডেল একই ফোল্ডে (paired তুলনা)
10	ফলাফল টেবিল, **Nadeau–Bengio সংশোধিত** ৯৫% CI (CV-তে ট্রেনিং সেট ওভারল্যাপ করে বলে সাধারণ CI খুব সংকীর্ণ হয়)
11	হাইপোথিসিস টেস্ট। H1: t = (গড় পার্থক্য + ০.০৩)/SE; H2: t = গড় পার্থক্য/SE; একপ্রান্তিক
12	Transparency বনাম Performance কার্ভ (প্রতিটি δ-এর জন্য)
13	Gate যাচাই: confident ও uncertain কেসে LR ও RF-এর accuracy
14	LR-এর odds ratio দিয়ে স্বচ্ছ অংশের ব্যাখ্যা
15	Robustness: ডুপ্লিকেট রেখে, এবং guilt প্রশ্ন বাদ দিয়ে পুনরায় চালানো
16–17, 19	**কঠোর সংস্করণ:** inner CV থেকে প্রতিটি ফোল্ডের ভেতরেই δ বাছা (সেরা ট্রেনিং স্কোরের ০.০১-এর মধ্যে সবচেয়ে ছোট δ)। উদ্দেশ্য: δ = 0.2 হাতে বাছা, এই সন্দেহ দূর করা
18	স্ক্রিনিং অপারেটিং পয়েন্ট: ট্রেনিং ডেটা থেকে থ্রেশহোল্ড ঠিক করে ৯০% sensitivity লক্ষ্য
20	Age band অনুযায়ী ফলাফল (fairness check)
21	Train বনাম test ফারাক (overfitting check)
22	আরও ৭ ধরনের মডেল (tuned RF, Extra Trees, SVM, HistGB, Categorical NB, k-NN, LR), inner 3-fold grid search সহ: "performance ceiling"
23	সব মডেলের তুলনার চার্ট ও টেবিল

৪. কোন মডেল কেন

মডেল	ভূমিকা	কেন
Logistic Regression	স্বচ্ছ বেস মডেল	odds ratio দিয়ে ব্যাখ্যা করা যায়; n = ৩২৬-এ variance কম
Random Forest (৩০০ গাছ, depth 8)	শক্তিশালী বেস মডেল	আগের বেঞ্চমার্কে সেরা (AUC ০.৮৩৫); উত্তরের interaction ধরতে পারে
Soft Voting	তুলনামূলক হাইব্রিড	দুই মডেল মেলানোর প্রচলিত পদ্ধতি
CGTH	**প্রস্তাবিত হাইব্রিড**	LR আত্মবিশ্বাসী হলে LR, নইলে RF
Gradient Boosting, XGBoost, deep learning	বাদ	RF-কে হারায়নি; ৩২৬ সারিতে deep learning অর্থহীন
SMOTE	বাদ	৫৮/৪২ মৃদু ভারসাম্যহীনতা; ক্যাটাগরিকাল ডেটায় শুধু near-duplicate বাড়ায়

Gate কেন কাজ করে (Task 13): LR confident কেসে ৮১% সঠিক, কিন্তু uncertain কেসে মাত্র ৬১%। ওই uncertain কেসে RF পায় ৭১%।

৫. ফলাফল

মূল তুলনা (৫০ ফোল্ড)

মডেল	Balanced accuracy [95% CI]	ROC-AUC	LR-এর সিদ্ধান্ত
LR	০.৭৩০ [০.৬৬৭, ০.৭৯৪]	০.৮০০	১০০%
RF	০.৭৬১ [০.৭০৬, ০.৮১৬]	০.৮৩৫	০%
Soft Voting	০.৭৪১ [০.৬৭৮, ০.৮০৪]	০.৮২০	—
CGTH	**০.৭৫৭ [০.৭০০, ০.৮১৩]**	০.৮০৯	**৬৮%**

হাইপোথিসিস

হাইপোথিসিস	পার্থক্য	p	ফল
H1 (ϑ = 0.2 স্থির)	−০.০০৫ বনাম RF	< ০.০০১	সমর্থিত
H1 (ϑ ফোল্ডের ভেতরে বাছা)	−০.০১১ বনাম RF	০.০৬	প্রমাণিত নয়
H2	+০.০২৬ বনাম LR	০.০৮	সমর্থিত নয়
H2 (কঠোর)	+০.০২০ বনাম LR	০.১৩	সমর্থিত নয়

অতএব H1 "ইঙ্গিতপূর্ণ" (suggestive), "প্রমাণিত" নয়।

Robustness

মডেল	ইউনিক সারি (মূল)	ডুপ্লিকেট রাখলে	Guilt বাদ দিলে
CGTH	০.৭৫৭	০.৮৪৩	০.৬০১
LR	০.৭৩০	০.৭৯৬	০.৬০১
RF	০.৭৬১	০.৮৫৫	০.৬০২
Soft Voting	০.৭৪১	০.৮১৩	০.৬০১

ডুপ্লিকেট রাখলে ফল কৃত্রিমভাবে ফোলে (leakage)। Guilt বাদ দিলে সব মডেল ~০.৬০-এ নেমে যায়, অর্থাৎ পুরো ফলাফল একটি প্রশ্নের উপর দাঁড়িয়ে।

অন্যান্য ফলাফল

- **৯০% sensitivity-তে specificity:** LR ০.৪৯৬, RF ০.৫৫৮, CGTH ০.৫০৯। এই পয়েন্টে RF-এর false alarm সবচেয়ে কম।
- **Age band (CGTH):** ২৫–৩০: ০.৬৬৪; ৩০–৩৫: ০.৮২৪; ৩৫–৪০: ০.৭৬০; ৪০–৪৫: ০.৭৫৫; ৪৫–৫০: ০.৭২৬। প্রতি band-এ ৪৯–৭৬ সারি, তাই শুধু বর্ণনামূলক।
- **Train বনাম test:** CGTH-এর balanced accuracy ফারাক ০.০৩৬, অর্থাৎ overfitting মৃদু।
- **Performance ceiling:** অন্য সব মডেল ০.৬৯–০.৭৬ এর মধ্যে। এই ডেটায় leakage ছাড়া প্রায় ০.৭৬-ই সীমা।
- **AUC:** CGTH-এর AUC, RF-এর চেয়ে কম, কারণ দুই মডেলের probability মেশালে র‍্যাঙ্কিং ঝাপসা হয়। CGTH একটি সিদ্ধান্ত-নিয়ম, তাই সিদ্ধান্ত-মেট্রিকই প্রাথমিক।

৬. গবেষণা পদ্ধতির শক্তিশালী দিক

1. **Leakage প্রতিরোধ:** ডিডুপ্লিকেশন স্প্লিটের আগে; imputation/encoding ট্রেনিং ফোল্ডের ভেতরে; থ্রেশহোল্ড ও ঠ বাছাই শুধু ট্রেনিং ডেটা থেকে।
2. **হাইপোথিসিস আগে ঠিক করা:** সেটিংস ও মার্জিন রান করার আগেই স্থির।
3. **সৎ রিপোর্টিং:** আংশিক ভেঙে যাওয়া H1 লুকানো হয়নি; বাতিল আইডিয়াগুলোও (tree-guided LR, guilt interaction) টেবিলে রাখা।
4. **পুনরুৎপাদনযোগ্যতা:** সব seed স্থির; লাইব্রেরি ভার্সন সেভ (Python 3.11, scikit-learn 1.9.1 ইত্যাদি)।
5. **অবদান নিয়ে সততা:** "অনিশ্চিত হলে শক্তিশালী মডেলে পাঠানো" ধারণাটা নতুন নয়; অবদান হলো পোস্টপার্টাম সার্ভেতে এর স্বচ্ছ-প্রথম প্রয়োগ ও coverage রিপোর্ট।

৭. সীমাবদ্ধতা

- ডেটার উৎস অজানা; লাইসেন্স ও এথিক্স অনুমোদন অযাচাইকৃত। ৩২৬ সারিও কৃত্রিম বা কপি হতে পারে।
- লেবেল একটি স্ব-রিপোর্টেড প্রশ্ন, রোগ নির্ণয় নয়; "early" প্রমাণ করা যায় না।
- Guilt প্রশ্নের উল্টো সম্পর্ক ক্লিনিক্যালি অসম্ভাব্য; মডেল একটি প্রশ্নের উপর অতিনির্ভরশীল।
- n = ৩২৬, external validation নেই; hyperparameter আগে থেকে স্থির।
- ঠ = 0.2 একটি অনুসন্ধানমূলক পরীক্ষার পর বাছা।
- Odds ratio শুধু সম্পর্ক দেখায়, কার্যকারণ নয়।

৮. বাকি কাজ (Roadmap)

- ডেটার উৎস ও লাইসেন্স যাচাই।
- সাহিত্য-তালিকার ⚠ চিহ্নিত রেফারেন্স যাচাই, বিশেষ করে ICSUMMIT 2026-এর পেপার, যা একই ডেটাসেটের উপর কাজ।
- EPDS লেবেলযুক্ত দ্বিতীয় ডেটাসেটে (যেমন Mendeley `4nznnrk8cg`, n = ৮০০) CGTH পরীক্ষা, যা journal-মানের জন্য সবচেয়ে বড় ধাপ।
- Secondary data ব্যবহারের এথিক্স ঘোষণা লেখা।

৯. ফাইল কাঠামো

```
research-projects/
├── README.md                    # প্রজেক্ট সারসংক্ষেপ
├── projects/
│   ├── cgth_hybrid_study.ipynb  # ★ মূল গবেষণা (২৩ Task)
│   ├── results_cgth/            # CSV/PNG/TXT ফলাফল
│   ├── 1-project, 2-project, main-projects, c_project  # পুরনো প্রচেষ্টা
│   └── ৩টি অভিন্ন CSV (byte-identical কপি)
└── research_blueprint/          # ০১–০৯: অডিট, শিরোনাম, সাহিত্য, হাইপোথিসিস, পদ্ধতি, থিসিস আউটলাইন
```

> **সারকথা:** পুরনো বেঞ্চমার্ক নোটবুকগুলোতে ডেটার মান ও মূল্যায়ন পদ্ধতিতে গুরুতর সমস্যা ছিল। সেটা ধরা পড়ার পর প্রজেক্টটি "ক্লিনিক্যাল ডিপ্রেশন স্ক্রিনিং" থেকে সরে একটি **পদ্ধতিগত গবেষণায়** পরিণত হয়েছে। এতে একটি ছোট নতুন হাইব্রিড (CGTH), কড়া leakage-মুক্ত মূল্যায়ন এবং সৎ ফলাফল আছে: CGTH, RF-এর কাছাকাছি নির্ভুলতা রাখে এবং ৬৮–৭৭% সিদ্ধান্ত স্বচ্ছ মডেলের হাতে রাখে। তবে এটি LR-এর চেয়ে উল্লেখযোগ্যভাবে ভালো প্রমাণিত নয়, আর ডেটার সীমাবদ্ধতার কারণে ক্লিনিক্যালি ব্যবহারযোগ্য নয়।