Complete Research Project Report / পূর্ণাঙ্গ গবেষণা প্রতিবেদন

Interpretable Postpartum Anxiety Screening-এর জন্য Confidence-Gated Transparent Hybrid Machine Learning

CGTH Project Report — English + বাংলা Mixed Edition (Updated)

Core project idea / মূল ধারণা: Logistic Regression-এর explainability এবং Random Forest-এর predictive strength-কে একটি confidence gate-এর মাধ্যমে combine করা।

প্রধান notebook: `notebooks/01_cgth_hybrid_study.ipynb`
রিপোর্টের তারিখ: ২ নভেম্বর ২০২৬

Executive Summary / সারসংক্ষেপ

এই প্রকল্পে postpartum survey data ব্যবহার করে একজন respondent-এর self-reported anxiety item অনুমান করার জন্য একটি ব্যাখ্যাযোগ্য hybrid machine-learning পদ্ধতি তৈরি ও মূল্যায়ন করা হয়েছে। প্রস্তাবিত **Confidence-Gated Transparent Hybrid (CGTH)**-এ Logistic Regression (LR) যখন নিজের prediction সম্পর্কে confident, তখন সে-ই final decision দেয়; probability 0.5-এর কাছাকাছি হলে কেবল সেই uncertain case Random Forest (RF)-এ পাঠানো হয়।

> **মূল ফলাফল:** duplicate সরানোর পর ৫০টি paired validation fold-এ CGTH balanced accuracy 0.757 [0.700, 0.813], RF-এর 0.761-এর খুব কাছাকাছি, অথচ ৬৮% decision সরাসরি transparent LR করেছে। তবে stricter, fold-wise threshold selection-এ RF-এর non-inferiority statisticalভাবে প্রতিষ্ঠিত হয়নি (p = 0.06); তাই ফলাফল promising, definitive নয়।

সবচেয়ে গুরুত্বপূর্ণ শিক্ষা হলো model score-এর চেয়ে data quality বেশি decisive: raw dataset-এর ৭৮% row duplicate/replicated pattern, label একটি clinical diagnosis নয়, এবং guilt item বাদ দিলে balanced accuracy প্রায় 0.60-এ নেমে যায়। তাই এই report-এ সাফল্যের সঙ্গে সীমাবদ্ধতা ও বাকি কাজও সমানভাবে বলা হয়েছে।

Table of Contents / সূচিপত্র

1. প্রকল্পের পটভূমি ও সমস্যা
2. উদ্দেশ্য, research questions ও hypotheses
3. Literature review ও research gap
4. Dataset, audit ও ethics
5. Methodology ও architecture
6. Evaluation ও statistical design
7. ফলাফল ও বিশ্লেষণ
8. Explainability, robustness ও fairness
9. Contribution, limitation ও clinical meaning
10. উপসংহার ও ভবিষ্যৎ roadmap

১. Project Background and Problem / প্রকল্পের পটভূমি ও সমস্যা

Postpartum period-এ উদ্বেগ ও বিষণ্ণতার উপসর্গ দ্রুত শনাক্ত করা গুরুত্বপূর্ণ। Machine learning questionnaire-এর বহু উত্তর থেকে risk signal ধরতে পারে, কিন্তু mental-health context-এ শুধু accuracy যথেষ্ট নয়। একজন clinician বা researcher-কে জানতে হয় কেন একটি decision এসেছে, কোন feature তার সঙ্গে সম্পর্কিত, এবং কোন ক্ষেত্রে model অনিশ্চিত।

এখানে মৌলিক trade-off হলো: LR সহজে odds ratio দিয়ে ব্যাখ্যা করা যায়, কিন্তু non-linear interaction ধরতে সীমিত; RF interaction ধরতে পারে, কিন্তু individual decision বোঝানো কঠিন। প্রচলিত soft voting সব case-এ দুই model-এর probability blend করে, ফলে কোনো decision-ই পুরোপুরি simple model-এর decision থাকে না। CGTH এই সমস্যায় “transparent first, complex only when needed” নীতি প্রয়োগ করে।

২. Objectives, Research Questions and Hypotheses / উদ্দেশ্য ও গবেষণা প্রশ্ন

1. Dataset-এর duplicate, missing value, timestamp ও label plausibility audit করা।
2. LR ও RF দিয়ে CGTH তৈরি করা।
3. Leakage-free repeated validation-এ LR, RF, soft voting ও CGTH তুলনা করা।
4. কত শতাংশ decision transparent LR করছে—coverage—তা মাপা।
5. LR decision odds ratio দিয়ে ব্যাখ্যা করা এবং transparency–performance curve তৈরি করা।
6. Duplicate leakage ও dominant guilt item-এর ওপর robustness পরীক্ষা করা।

> **H1:** CGTH RF-এর চেয়ে balanced accuracy-তে 0.03 margin-এর মধ্যে non-inferior হবে।
> **H2:** CGTH LR-এর চেয়ে superior হবে। Primary metric balanced accuracy; ROC-AUC secondary।

৩. Literature Review and Research Gaps / সাহিত্য পর্যালোচনা ও research gap

পর্যালোচিত literature-এ তিনটি ধারা দেখা যায়। বড় EHR cohort-এ sample বড় হলেও documented diagnosis এবং symptom screening এক নয়। ছোট questionnaire study-তে AUC বেশি দেখা যায়, কিন্তু single-site data, small-n optimism এবং internal-only validation-এর ঝুঁকি থাকে। Review papers validation inconsistency, variable selection এবং reporting bias-এর কথা বলেছে।

ধারা	সাহিত্যে সাধারণ চিত্র	এই প্রকল্পের প্রতিক্রিয়া
ডেটা	EHR-ভিত্তিক বড় cohort অথবা ছোট single-site questionnaire; provenance ও duplication audit সবসময় থাকে না।	Raw data অপরিবর্তিত রেখে duplicate, missing cell, timestamp ও label plausibility audit করা হয়েছে।
Label	EPDS/PHQ স্কোর, diagnosis code বা symptom label—ফলাফল একরকম নয়।	এখানে `Feeling anxious` self-reported item; clinical diagnosis হিসেবে দাবি করা হয়নি।
Validation	Single split বা internal CV বেশি; optimistic point estimate-এর ঝুঁকি থাকে।	Stratified 5-fold × 10 repeat = 50 paired folds এবং corrected CI ব্যবহার করা হয়েছে।
Ensemble	Voting/stacking সাধারণত সব case-এ একসঙ্গে ব্যবহার হয়।	Transparent-first gate: confident case LR নেয়, uncertain case RF-তে যায়।
Explainability	SHAP/feature plot দেখানো হয়, কিন্তু কত case simple model decide করেছে তা মাপা হয় না।	LR coverage এবং transparency–performance curve রিপোর্ট করা হয়েছে।

Specific Gaps Addressed by This Project / এই প্রকল্পে address করা gap

Gap	সমস্যা	এই প্রকল্পে উত্তর
G1	Public survey data-তে duplicate/replication audit অনিয়মিত।	১,৫০৩ raw row থেকে unique pattern, missingness ও label anomaly পরিমাপ।
G2	Single split-এর point estimate optimistic হতে পারে।	৫০টি paired fold, corrected CI এবং hypothesis test।

Gap	সমস্যা	এই প্রকল্পে উত্তর
G3	Hybrid সাধারণত সব case-এ blend করে।	Confident case LR; uncertain case RF।
G4	Explainability plot আছে, কিন্তু transparent decision coverage নেই।	৬৮% LR coverage ও delta curve রিপোর্ট।
G5	Ensemble superiority প্রায়ই ধরে নেওয়া হয়।	Pre-stated non-inferiority বনাম RF এবং superiority বনাম LR test।
G6	একটি dominant item headline result চালাতে পারে।	Guilt item বাদ দিয়ে পূর্ণ experiment পুনরায় চালানো।

Novelty সততার সঙ্গে: confidence-based cascade বা selective classification নতুন ধারণা নয়। এই কাজের অবদান হলো postpartum survey setting-এ transparent-first cascade প্রয়োগ, coverage-কে performance-এর পাশে report করা এবং data-quality failure-কে ফলাফলের অংশ করা।

8. Dataset, Data Audit and Ethics / ডেটাসেট, audit ও নৈতিকতা

Source হলো Kaggle-এর *PostPartum Depression* dataset; uploader: `parvezalmuqtadir2348`। Raw file-এ ১,৫০৩ row ও ১১ column: timestamp, age band এবং ৯টি categorical survey item। Target হিসেবে `Feeling anxious`-এর Yes/No নেওয়া হয়েছে। Raw data কখনও overwrite করা হয়নি; preprocessing notebook-এর pipeline-এর ভিতরে হয়েছে।

Audit item	ফলাফল	অর্থ
Raw rows	1,503	প্রথমে দেখা sample size; model-এর effective independent sample নয়।
Unique answer patterns	326	প্রায় ৭৮% duplicate/replicated row; leakage-এর বড় ঝুঁকি।
Missing cells	27	Most-frequent imputation training fold-এর ভিতরে fit করা হয়েছে।
Distinct timestamps	90	একই সময়/response pattern replication-এর সম্ভাবনা।
Label	Self-reported anxiety item	Validated clinical diagnosis নয়।

> **Ethics ও safe use:** dataset-এ mental-health item এবং suicide-related question আছে। এটি individual clinical diagnosis, triage বা treatment recommendation-এর জন্য নয়। Kaggle licence ও provenance redistributing-এর আগে যাচাই করতে হবে; anonymisation এবং secure storage বজায় রাখতে হবে।

৫. Methodology: From Preprocessing to Final Decision / preprocessing থেকে final decision

1. Timestamp drop করা হয়েছে, কারণ এটি clinical predictor নয় এবং collection order-এর proxy হতে পারে।
2. Exact duplicate row split-এর আগেই বাদ দেওয়া হয়েছে, যাতে একই response train ও validation-এ না থাকে।
3. Missing categorical value-এর most-frequent imputation এবং one-hot encoding কেবল training fold-এ fit করা হয়েছে; validation fold-এ তথ্য leak হয়নি।
4. LR ও RF একই fold, একই threshold এবং একই transformed features পেয়েছে।
5. LR probability p-এর জন্য delta = 0.2: $|p - 0.5| \geq 0.2$ হলে LR final decision; নইলে RF decision।

```
respondent answers
        |
fold-specific imputation + one-hot encoding
        |
Logistic Regression → probability p
        |
    |p − 0.5| ≥ δ ?
      ┌─────┴──────┐
     হ্যাঁ          না
      |              |
 final = LR      final = RF
 explainable     uncertain case only
```

Why These Two Models? / কেন এই দুই model?

Model	ভূমিকা	কেন ব্যবহার
Logistic Regression	Transparent base	Odds ratio, low variance, categorical survey data-তে readable association।
Random Forest	Stronger nonlinear base	Feature interaction ধরতে পারে; এই data-তে single-model benchmark-এর সেরা ফল।
Soft voting	Comparator hybrid	প্রচলিত probability averaging-এর fair baseline।
CGTH	Proposed method	Simple model confident হলে complexity না বাড়িয়ে decision; uncertain হলে RF-এর সাহায্য।

৬. Evaluation and Statistical Design / evaluation ও statistical design

Dataset ছোট হওয়ায় আলাদা 66-row hold-out অত্যন্ত noisy হতে পারে। তাই stratified 5-fold cross-validation 10 বার repeat করে মোট ৫০টি paired fold ব্যবহার করা হয়েছে। সব model একই folds ব্যবহার করায় model differences paired। Primary metric balanced accuracy, কারণ class ratio প্রায় 58/42 এবং শুধু raw accuracy majority class-এর দিকে ঝুঁকতে পারে। Secondary metrics: accuracy, sensitivity, specificity, F1, MCC এবং ROC-AUC।

Nadeau–Bengio corrected standard error দিয়ে 95% confidence interval তৈরি করা হয়েছে; cross-validation training sets overlap করে বলে সাধারণ fold standard error অতিরিক্ত optimistic হতে পারে। H1-এর জন্য one-sided non-inferiority margin 0.03, H2-এর জন্য one-sided superiority test। Non-significant ফলকে "সমান প্রমাণিত" না বলে "significant evidence নেই" বলা হয়েছে।

দুটি validation view রাখা হয়েছে: fixed exploratory $\delta = 0.2$ এবং training fold-এর ভিতর δ নির্বাচন করা stricter analysis। এই separation tuning optimism সম্পর্কে সৎ ধারণা দেয়।

৭. ফলাফল

৭.১ Main Model Comparison / প্রধান model comparison

মডেল	Balanced accuracy (95% CI)	Accuracy	Sensitivity	Specificity	ROC-AUC	LR coverage
Logistic Regression	0.730 [0.667, 0.794]	0.745	0.821	0.639	0.800	100%
Random Forest	0.761 [0.706, 0.816]	0.780	0.881	0.642	0.835	0%
Soft Voting (LR+RF)	0.741 [0.678, 0.804]	0.760	0.857	0.626	0.820	—
CGTH (প্রস্তাবিত)	**0.757 [0.700, 0.813]**	0.776	0.878	0.635	0.809	**68%**

CGTH-এর balanced accuracy RF-এর চেয়ে মাত্র 0.005 কম এবং LR coverage 68%। অর্থাৎ decision performance RF-এর কাছাকাছি রেখে অধিকাংশ decision simple model-এর হাতে রাখা সম্ভব হয়েছে—fixed δ analysis-এ এটি প্রকল্পের প্রধান empirical result। তবে CGTH-এর ROC-AUC RF-এর চেয়ে কম (0.809 বনাম 0.835), কারণ দুই model-এর decision probability মিশে ranking quality কমে। CGTH একটি decision policy; তাই balanced accuracy primary হওয়া যুক্তিসঙ্গত।

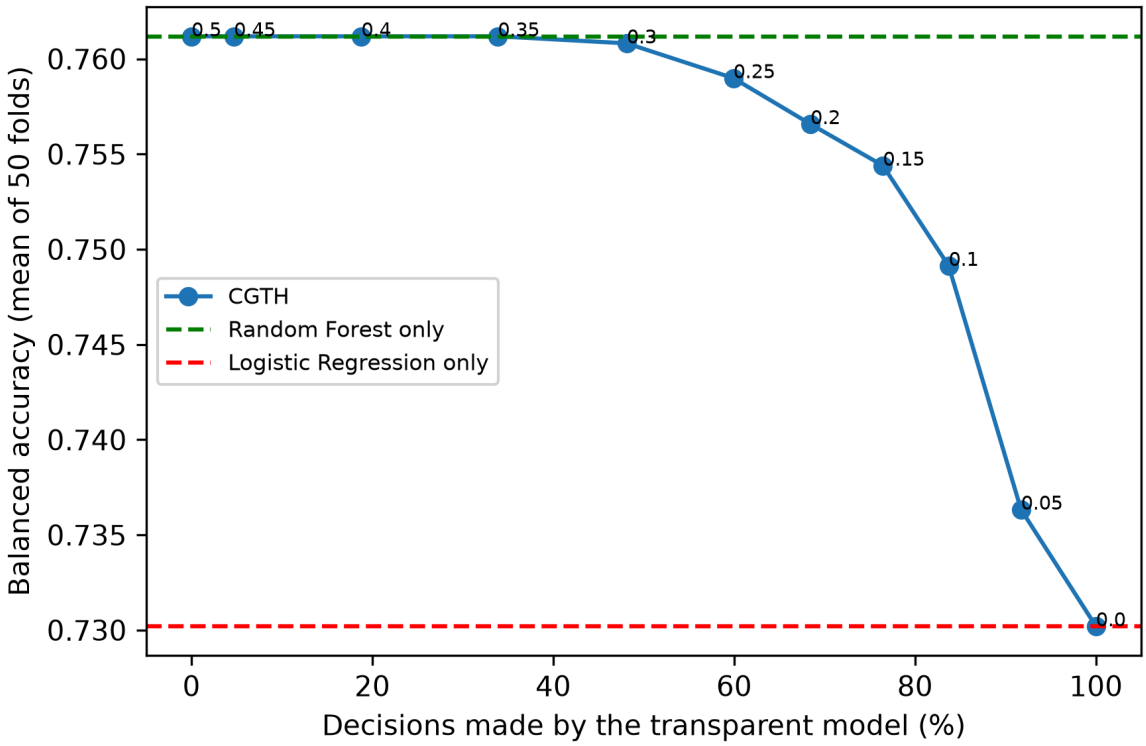
৭.২ Hypothesis Tests / hypothesis পরীক্ষা

Hypothesis	Observed difference	p-value	Interpretation
H1 fixed δ=0.2: CGTH non-inferior to RF	−0.0046	<0.001	সমর্থিত, কিন্তু δ exploratoryভাবে দেখা হয়েছিল।
H2: CGTH better than LR	+0.0264	0.080	Significant evidence নেই।
Strict H1: δ training fold-এ নির্বাচন	−0.0112	0.060	Non-inferiority প্রতিষ্ঠিত নয়; ফলাফল suggestive।
Strict H2	+0.0197	0.127	Significant evidence নেই।

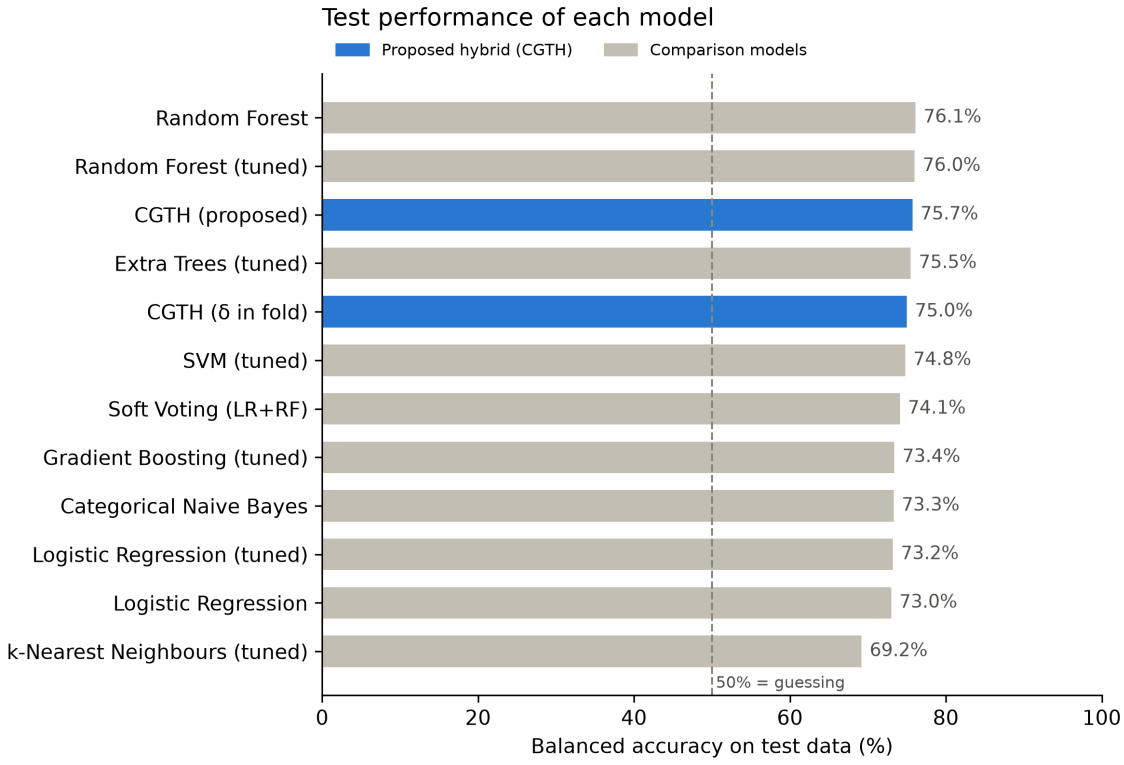
৭.৩ Why Does the Gate Work? / gate কেন কাজ করে?

Condition	Accuracy
LR on confident cases	0.806
LR on uncertain cases	0.606
RF on uncertain cases	0.709

এই ফল CGTH-এর mechanism support করে: LR confident case-এ ভালো, কিন্তু boundary case-এ RF তুলনামূলকভাবে বেশি useful।



চিত্র ১: Delta বাড়লে transparent LR coverage ও balanced accuracy-এর trade-off।



চিত্র ২: প্রধান model-গুলোর comparative ফল।

৮. Robustness, Performance Ceiling and Subgroup Analysis / robustness ও subgroup analysis

৮.১ Data-quality Robustness / data-quality robustness

Model	Unique rows	Duplicates kept	Guilt item removed
CGTH	0.757	0.843	0.601
LR	0.730	0.796	0.601
RF	0.761	0.855	0.602
Soft voting	0.741	0.813	0.601

Duplicates রেখে score 0.84–0.86 হওয়া স্পষ্ট leakage inflation। Guilt item বাদ দিলে সব model প্রায় 0.60—তাই headline performance-কে clinically meaningful general signal ধরে নেওয়া যাবে না।

৮.২ Performance Ceiling / performance ceiling

Tuned RF, Extra Trees, SVM, Gradient Boosting, categorical Naive Bayes, tuned LR এবং k-NN-এর balanced accuracy আনুমানিক 0.69–0.76। অর্থাৎ এই data ও label-এ leakage ছাড়া প্রায় 0.76-এর কাছাকাছি একটি ceiling দেখা যায়; শুধু আরও complex model যোগ করলে বড় উন্নতি হওয়ার প্রমাণ নেই।

৮.৩ Age-band Descriptive Check / age-band বিশ্লেষণ

Age band	Unique rows	Balanced accuracy	Sensitivity	Specificity	LR coverage
25–30	49	0.664	0.748	0.581	0.624
30–35	71	0.824	0.967	0.681	0.601
35–40	76	0.760	0.826	0.693	0.774
40–45	73	0.755	0.878	0.633	0.656
45–50	57	0.726	0.927	0.525	0.756

Age-band ফল fairness proof নয়: প্রতিটি band-এ unique row মাত্র 49–76। এটি subgroup monitoring-এর শুরু, final fairness claim নয়।

৮.৪ Train–Test Gap / train–test gap

CGTH balanced accuracy train 0.792 বনাম validation/test 0.757; gap 0.036। RF-এর gap 0.035 এবং AUC gap 0.099। এই gap small-n generalisation uncertainty দেখায়, কিন্তু external validation-এর বিকল্প নয়।

৯. Explainability, Contributions and Practical Benefits / explainability ও ব্যবহারিক benefit

- **Individual transparency:** LR-decided case odds ratio দিয়ে কোন response association decision-এ অবদান রেখেছে তা বোঝানো যায়।
- **Coverage:** 68% decision transparent model করেছে; stricter fold-wise ϑ-তে coverage 77%, কিন্তু statistical guarantee দুর্বল হয়েছে।
- **Operational benefit:** সব case-এ black-box model না চালিয়ে audit-friendly default রাখা যায়; uncertain case আলাদা queue বা second review-তে পাঠানো যায়।
- **Research benefit:** শুধু best AUC নয়, performance–transparency trade-off মাপা হয়েছে।

Odds ratio association, causation নয়। কোনো survey answer postpartum anxiety-এর clinical cause প্রমাণ করে না। SHAP/LIME যোগ করা গেলেও তা এই data-এর label validity বা external generalisation ঠিক করবে না; explanation stability resample-এর ওপর ভবিষ্যতে মাপা উচিত।

১০. Limitations, Reviewer Criticism and Honest Interpretation / সীমাবদ্ধতা

সম্ভাব্য প্রশ্ন	সৎ উত্তর
এটি কি clinical screening model?	না। এটি self-reported anxiety item prediction; validated clinical reference standard নেই।
CGTH কি প্রমাণিতভাবে RF-এর সমান?	Fixed δ-তে H1 সমর্থিত; fold-wise δ selection-এ p=0.06, তাই definitive নয়।
CGTH কি LR-এর চেয়ে better?	Observed gain +0.026, কিন্তু p=0.08; superiority প্রমাণিত নয়।
Dataset reliable?	না বলা যাবে না: provenance unclear, 78% duplicates, 90 timestamp, single-item label। Audit এগুলো quantify করেছে।
Novelty কী?	Cascade ধারণা পুরনো; novelty হলো এই setting-এ transparent-first application ও coverage reporting।
External validation আছে?	নেই; দ্বিতীয় independent validated dataset প্রয়োজন।
Hyperparameter tuning?	Main LR/RF settings pre-fixed; broader ceiling analysis-এ inner tuning করা হয়েছে।

১১. Reproducibility and Project Structure / reproducibility ও project structure

মূল experiment এক notebook-এ ২২টি task হিসেবে রাখা হয়েছে। Raw dataset read-only; outputs `results/`-এ CSV এবং PNG হিসেবে সংরক্ষিত। Seed 42, δ grid, non-inferiority margin এবং library versions সংরক্ষণ করা হয়েছে। এই separation audit trail তৈরি করে এবং একই result পুনরায় চালানোর সুযোগ বাড়ায়।

Path	ভূমিকা
`data/DATA_CARD.md`	Source, size, ethics, known issues।
`research_plan/01–09`	Audit, literature, hypotheses, architecture, methodology, limitations, roadmap।
`notebooks/01_cgth_hybrid_study.ipynb`	পুরো leakage-free analysis pipeline।
`results/*.csv`	Model metrics, tests, robustness, subgroup ও ceiling outputs।
`results/*.png`	Comparison ও transparency figures।

১২. Remaining Work: Priority Roadmap / কী কী করা বাকি

1. **অবিলম্বে:** Kaggle provenance/licence যাচাই এবং একই dataset নিয়ে prior 2026 analysis পূর্ণপাঠে যাচাই।

2. **ডেটা:** validated EPDS/PHQ বা clinician-verified outcome-সহ independent Bangladesh বা multi-site dataset সংগ্রহ।
3. **Validation:** temporal/external validation, pre-registered threshold, sample-size justification এবং calibration curve/Brier score যোগ করা।
4. **Clinical utility:** decision-curve analysis, false-negative cost, referral threshold এবং clinician-in-the-loop usability study।
5. **Fairness:** age ছাড়াও parity, calibration ও error-rate subgroup analysis; যথেষ্ট subgroup sample ছাড়া claim না করা।
6. **Explainability:** bootstrap/resample-এ odds ratio ও explanation stability, uncertainty intervals, এবং user-facing explanation test।
7. **Reporting:** TRIPOD+AI checklist, complete feature dictionary, preprocessing code, model card ও data-use statement যোগ করা।

> **Publication-ready হওয়ার প্রধান শর্ত:** দ্বিতীয় independent dataset-এ validated label দিয়ে result replicate করা। এটি নতুন algorithm যোগ করার চেয়ে অনেক বেশি গুরুত্বপূর্ণ উন্নতি হবে।

১৩. Conclusion / উপসংহার

CGTH একটি বাস্তবসম্মত, audit-friendly hybrid design: simple model confident হলে explanation বজায় থাকে, uncertain case-এ stronger RF ব্যবহার হয়। এই project-এ 68% transparent coverage সহ RF-এর কাছাকাছি balanced accuracy পাওয়া গেছে। কিন্তু এই সাফল্যকে clinical performance বলা যাবে না, কারণ data duplication, unclear provenance, self-reported single-item label এবং small effective sample বড় সীমাবদ্ধতা।

সুতরাং প্রকল্পটির সবচেয়ে শক্তিশালী উন্নতি হলো শুধু নতুন model নয়—সঠিক audit, leakage-free validation, corrected uncertainty, honest hypothesis reporting এবং transparency–performance trade-off। পরবর্তী ধাপে external validated data ও clinical utility evaluation যোগ হলে CGTH ধারণাটি গবেষণা থেকে দায়িত্বশীল screening-support prototype-এর দিকে এগোতে পারবে।

References and Methodology Sources / তথ্যসূত্র

1. Zhang et al. (2020), *JMIR Medical Informatics*, 8(4):e15516.
2. Shin, Lee, Adeluwa & Hur (2020), *Journal of Clinical Medicine*, 9(9):2899.
3. Hochman et al. (2021), *Depression and Anxiety*, 38(4):400–411.
4. Amit et al. (2021), *BMC Pregnancy and Childbirth*, 21:630.
5. Saqib, Khan & Butt (2021), *JMIR Mental Health*, 8(11):e29838.
6. Cellini et al. (2022), *Journal of Affective Disorders*, 309.
7. Collins et al. (2024), TRIPOD+AI, *BMJ*, 385:e078378.
8. Huang et al. (2025), *Frontiers in Medicine*, doi:10.3389/fmed.2025.1565374.
9. Xia et al. (2025), *Frontiers in Public Health*, doi:10.3389/fpubh.2025.1631705.
10. Alkhateeb et al. (2026), *Journal of Medical Internet Research*, 28:e77376.
11. Lundberg & Lee (2017), SHAP; Ribeiro et al. (2016), LIME; Nadeau & Bengio (2003), corrected resampling.

নোট: Literature review-এর যেসব entry-র metadata research plan-এ অসম্পূর্ণ হিসেবে চিহ্নিত, সেগুলো final thesis bibliography-তে DOI/journal page দেখে পুনরায় যাচাই করতে হবে।